SISTEMA DE MONITORAMENTO DE FRESADORAS INDUSTRIAIS BASEADO EM IIOT

IIoT-based monitoring system for industrial milling machines

Alecsander Silva – Faculdade de Tecnologia “Adib Moisés Dib” de São Bernardo do Campo
alecsander.silva@aluno.cps.sp.gov.br

Gabriel Ricardo da Silva – Faculdade de Tecnologia “Adib Moisés Dib” de São Bernardo do Campo
gabriel.silva192@aluno.cps.sp.gov.br

Jose Cleiton da Silva – Faculdade de Tecnologia “Adib Moisés Dib” de São Bernardo do Campo
jose.silva35@aluno.cps.sp.gov.br

Orientador: Prof. Dr. William Aparecido Celestino Lopes – Faculdade de Tecnologia “Adib Moisés Dib” de São Bernardo do Campo

RESUMO

Muitas pequenas e médias indústrias ainda operam máquinas sem nenhum registro automático de funcionamento, o que dificulta a manutenção, o cálculo do custo da hora-máquina e a investigação de falhas. Em visitas à empresa AMJ Máquinas e Ferramentas, em Diadema (SP), verificou-se que as fresadoras não tinham histórico de operação nem medição de consumo de energia e que o motor principal de uma delas sofria desarmes e aquecimento. Este estudo, de caráter exploratório, desenvolveu e avaliou, por *Design Science Research* (DSR), um protótipo de *Industrial Internet of Things* (IIoT) de baixo custo para monitoramento de uma fresadora industrial, integrando ESP32, sensoriamento elétrico com o PZEM-004T, MQTT, painel de visualização e classificação local por rede neural de 107 parâmetros (TinyML). Após o tratamento das leituras coletadas entre 25 e 29 de setembro de 2026, foram obtidas 2.613 amostras candidatas, das quais 2.386 foram efetivamente particionadas no teste em blocos; a acurácia foi de 99,7% nesse teste, com 304 leituras, e de 98,7% em teste com dias distintos, com F1 macro de 0,987 (classes VAZIO e USINANDO) e de 0,946 (três classes), respectivamente. A interpretação desses resultados é condicionada pela rotulagem baseada em corrente e pela representatividade limitada de alguns estados. Na campanha inicial, a corrente e a tensão foram tomadas na saída de um inversor de frequência, o que restringe a validade metrológica das grandezas registradas; em outubro, apenas a derivação de tensão foi transferida para o disjuntor geral da máquina. A avaliação com seis usuários da empresa resultou em pontuação SUS média de 83,8. O protótipo demonstrou viabilidade funcional para a aquisição periódica e a visualização de registros do comportamento operacional nas sessões analisadas, permanecendo necessária validação adicional para diagnóstico de falhas e aplicação em condições industriais distintas.

Palavras-chave: IIoT; ESP32; PZEM-004T; TinyML; monitoramento industrial.

ABSTRACT

Many small and medium-sized manufacturers still run machines without any automatic record of their operation, which makes maintenance, machine-hour costing and failure analysis difficult. During visits to AMJ Máquinas e Ferramentas, in Diadema, Brazil, it was found that the milling machines had no operating history or energy measurement, and that the main motor of one of them was tripping and overheating. This exploratory study used Design Science Research (DSR) to develop

and evaluate a low-cost Industrial Internet of Things (IIoT) prototype for monitoring an industrial milling machine, integrating an ESP32, electrical sensing with a PZEM-004T, MQTT, a visualization dashboard and local classification by a 107-parameter neural network (TinyML). Data treatment of the readings collected from 25 to 29 September 2026 yielded 2,613 candidate samples, of which 2,386 were effectively partitioned in the block test; accuracy was 99.7% on that test, with 304 readings, and 98.7% on a test with different days, with macro F1 of 0.987 (VAZIO and USINANDO classes) and 0.946 (three classes), respectively. The interpretation of these results is conditioned by the current-based labeling and by the limited representation of some states. In the initial campaign, current and voltage were taken at the output of a frequency inverter, which restricts the metrological validity of the recorded quantities; in October, only the voltage connection was moved to the main breaker of the machine. The evaluation with six users from the company resulted in a mean SUS score of 83.8. The prototype showed functional feasibility for periodic acquisition and visualization of records of operating behavior in the analyzed sessions, and further validation is still required for fault diagnosis and for application under different industrial conditions.

Keywords: IIoT; ESP32; PZEM-004T; TinyML; industrial monitoring.

1 INTRODUÇÃO

A transformação digital tem levado a indústria a adotar tecnologias da Indústria 4.0 para acompanhar a produção em tempo real e decidir com base em dados. A *Industrial Internet of Things* (IIoT) é uma das peças centrais desse movimento, porque liga sensores, sistemas embarcados e plataformas de software e permite coletar variáveis do processo diretamente no chão de fábrica (KHANG *et al.*, 2024).

Grandes empresas já integram a tecnologia operacional (OT) à tecnologia da informação (IT) para ganhar rastreabilidade e reduzir a dependência de registros manuais. Nas pequenas e médias empresas, porém, ainda é comum encontrar máquinas sem nenhuma ligação com sistemas supervisórios ou de manutenção, cujo uso só é conhecido pelo relato dos operadores (OKANO *et al.*, 2026).

Uma forma barata de mudar esse cenário é medir as grandezas elétricas do motor. Um microcontrolador ESP32, que já tem Wi-Fi integrado, ligado a um sensor não invasivo como o PZEM-004T, consegue registrar a corrente, a tensão e a potência da máquina e publicá-las pelo protocolo MQTT para painéis de *Business Intelligence* (BI) (SANTOS *et al.*, 2023; HERCOG *et al.*, 2023).

Esse foi o ponto de partida deste trabalho. Em visitas técnicas à AMJ Máquinas e Ferramentas, em Diadema (SP), constatou-se que as fresadoras não

tinham histórico de funcionamento, o que deixava a empresa sem saber se as máquinas estavam sendo usadas de forma adequada. O proprietário também relatou que não conseguia medir o consumo de energia de cada fresadora e, por isso, não calculava com precisão o custo da hora-máquina.

Em estudo aplicado à manutenção de máquinas em uma empresa fabricante de teares, Souza *et al.* (2024) também identificaram limitações associadas ao registro e ao acesso às informações de manutenção, propondo um artefato digital fundamentado em *Design Science Research*. Essa aproximação evidencia a recorrência do problema informacional, embora as soluções tecnológicas tenham objetivos distintos.

Diante desse cenário, formula-se a seguinte questão de pesquisa: em que medida um artefato IIoT de baixo custo, com inferência embarcada, permite registrar e distinguir estados operacionais de uma fresadora em ambiente fabril, e quais são as limitações da classificação quando os rótulos se baseiam nas próprias medições elétricas? A contribuição do estudo consiste na implementação e avaliação contextualizada da arquitetura de aquisição, comunicação e inferência, incluindo a comparação entre o comportamento observado em operação e as restrições de medição e generalização identificadas durante os testes.

Assim, o objetivo deste trabalho é desenvolver e avaliar um artefato de IIoT de baixo custo que monitore as variáveis elétricas de uma fresadora, identifique o seu estado de operação no próprio dispositivo, com aprendizado de máquina embarcado (TinyML), e envie os dados para um painel de acompanhamento que apoie a manutenção e a investigação de falhas.

2 FUNDAMENTAÇÃO TEÓRICA

2.1 IIoT e monitoramento na Indústria 4.0

A Indústria 4.0 integra sistemas físicos e digitais por meio de automação, conectividade e processamento de dados. Quando máquinas, sensores e sistemas computacionais trocam informações, a operação fica mais visível e a empresa depende menos de anotações manuais (CHAUHAN *et al.*, 2023). Nesse contexto, a convergência entre OT e IT é decisiva: os sistemas de OT, que controlam máquinas e processos, passam a alimentar os sistemas de IT, que armazenam e analisam os

dados para apoiar a produção e a manutenção (LOPES; RUGGERO; OKANO, 2026).

A IIoT aplica os conceitos da Internet das Coisas ao ambiente industrial e é usada para monitorar ativos e supervisionar processos. Com ela, variáveis como corrente, temperatura e vibração passam a ser acompanhadas de forma contínua, o que permite identificar padrões de uso, tempos de parada e condições anormais sem depender de inspeções manuais (KHANG *et al.*, 2024).

A integração entre aquisição de dados no chão de fábrica e armazenamento remoto também foi abordada por Lopes, Mendes e Mario (2017) no contexto de sistemas ciberfísicos para a Indústria 4.0. No presente trabalho, essa lógica é retomada em uma arquitetura de monitoramento que adiciona inferência local e visualização dos registros.

Para levar esses dados do chão de fábrica até a nuvem, o protocolo MQTT (*Message Queuing Telemetry Transport*) é uma das opções mais adotadas. Ele funciona no modelo publicação/assinatura (*publish/subscribe*): o dispositivo publica mensagens em um tópico de um servidor intermediário, o *broker*, e os sistemas interessados assinam esse tópico. Por gerar pouco tráfego e ser simples de implementar, o MQTT se adapta bem a microcontroladores como o ESP32 (HERCOG *et al.*, 2023).

2.2 Sistemas embarcados e sensoriamento elétrico

Sistemas embarcados reúnem microcontroladores, sensores e interface de comunicação para executar tarefas específicas, como medir e transmitir variáveis, com baixo custo e baixo consumo de energia. O ESP32 se destaca nessa categoria por ter processador de dois núcleos, Wi-Fi e Bluetooth integrados e suporte a vários protocolos de comunicação. Em contrapartida, aplicações industriais sem fio precisam considerar interferência eletromagnética, estabilidade do sinal e latência (HERCOG *et al.*, 2023).

A seleção de plataformas embarcadas para aplicações de IoT pode considerar simultaneamente funcionalidades essenciais, capacidade de processamento e custo de implementação, conforme a abordagem de inovação frugal discutida por Lopes *et al.* (2024). Essa perspectiva é pertinente à escolha de um microcontrolador acessível para o monitoramento de máquinas industriais.

O PZEM-004T é um módulo de medição para corrente alternada que fornece tensão, corrente, potência ativa, frequência, fator de potência e energia acumulada, sendo usado com frequência em protótipos de monitoramento de consumo (YASA *et al.*, 2023). Segundo o fabricante, ele foi projetado para redes senoidais entre 45 e 65 Hz (PEACEFAIR, [20--]), limite importante quando a medição é feita em circuitos com inversor de frequência.

Em motores de indução, como o de uma fresadora, a corrente cresce com a carga mecânica. Por isso, acompanhar a corrente ao longo do tempo permite separar períodos de máquina parada, girando em vazio ou cortando material, além de revelar mudanças de comportamento que podem indicar falhas. Esses registros formam a base de dados necessária para a manutenção baseada em condição (DE LAS MORENAS; MOYA-FERNÁNDEZ; LÓPEZ-GÓMEZ, 2023). Quando o motor é acionado por inversor, a frequência de alimentação define a velocidade do eixo: até a frequência nominal, o inversor aumenta a tensão junto com a frequência e mantém o torque; acima dela, a tensão fica no máximo e o torque disponível cai, região conhecida como enfraquecimento de campo (WEG, 2026; SCHMERSAL, 2023).

A medição de grandezas elétricas na saída de inversores de frequência exige instrumentos compatíveis com formas de onda moduladas por largura de pulso (PWM). Quando o medidor é especificado para redes senoidais e faixa limitada de frequência, suas indicações de frequência, tensão, potência e fator de potência não devem ser consideradas equivalentes a medições metrologicamente validadas na alimentação do motor. Assim, a verificação da frequência efetiva de comando e de eventuais causas de desarme requer consulta aos parâmetros e registros do inversor, bem como instrumento apropriado para essa condição de medição.

2.3 TinyML e computação de borda

O *Tiny Machine Learning* (TinyML) é a execução de modelos de aprendizado de máquina em microcontroladores de baixo custo e baixo consumo (ABADADE *et al.*, 2023). A ideia central é separar duas etapas: o treinamento, que exige mais processamento, é feito em um computador; o microcontrolador recebe apenas os pesos e os vieses (*bias*) do modelo e faz a inferência, isto é, classifica cada nova leitura (DAVID *et al.*, 2021; ELHANASHI *et al.*, 2024).

Processar os dados no próprio dispositivo, a chamada computação de borda (*edge computing*), reduz o volume enviado pela rede, diminui a latência e mantém o sistema funcionando mesmo com a conexão instável. Okano *et al.* (2025) mostraram essa viabilidade na indústria automotiva ao substituir gabaritos físicos de inspeção por um modelo de visão computacional executado em um Raspberry Pi, sem placa de vídeo dedicada. No monitoramento de motores, a mesma lógica permite que o ESP32 reconheça o estado da máquina a partir da corrente e envie apenas o resultado e as medições (ABADADE *et al.*, 2023).

Um dos modelos mais simples para esse fim é o Perceptron Multicamadas (MLP). Cada neurônio calcula uma soma ponderada das entradas, $z = \Sigma(w_i \cdot x_i) + b$, e aplica uma função de ativação. A função ReLU, $f(z) = \max(0, z)$, é simples de calcular e permite que a rede aprenda fronteiras não lineares; na saída, a função *softmax* transforma as pontuações em probabilidades para cada classe. O treino ajusta pesos e vieses pelo algoritmo de *backpropagation*, de modo a reduzir uma função de perda como a entropia cruzada (ELHANASHI *et al.*, 2024).

Os pesos (w) indicam quanto cada entrada influencia o neurônio. O viés (b, do inglês *bias*) é um valor somado ao resultado que desloca o ponto a partir do qual o neurônio é ativado, de forma parecida com o ajuste de zero de um instrumento. Pesos e vieses são os parâmetros treináveis da rede, ou seja, os números que o treino ajusta. O treinamento da rede neural ocorre em computador externo; no microcontrolador são armazenados os pesos, os vieses e os parâmetros de normalização necessários à inferência. Os coeficientes da rede atuam em conjunto com as transformações não lineares e, isoladamente, não constituem medida direta da importância de uma variável de entrada.

Para saber se a rede está acertando, usam-se duas medidas. A função de perda mede o erro de cada previsão; na entropia cruzada, $L = -\Sigma\, y \cdot \log(\hat{y})$, atribuir 90% de probabilidade à classe correta resulta em $L = 0{,}11$, enquanto atribuir 31% resulta em $L = 1{,}17$, de modo que a rede é mais punida quando erra com confiança. Já a acurácia é a fração de leituras classificadas corretamente e é a medida usada para comparar o modelo com outras abordagens.

O *backpropagation* (retropropagação do erro) é o algoritmo que ajusta pesos e vieses. O treino repete quatro passos: na propagação direta, as entradas atravessam a rede e geram uma previsão; em seguida, a perda é calculada; na

retropropagação, a regra da cadeia indica quanto cada peso contribuiu para o erro, o gradiente $\partial L/\partial w$; por fim, cada peso é corrigido no sentido que reduz o erro, $w \leftarrow w - \eta \cdot \partial L/\partial w$, em que η é a taxa de aprendizado. Otimizadores como o Adam adaptam o tamanho dessa correção para cada parâmetro, e cada passada completa pelos dados de treino é chamada de época (ELHANASHI *et al.*, 2024).

3 METODOLOGIA

Esta pesquisa combina a pesquisa bibliográfica e o *Design Science Research* (DSR). A abordagem é quali-quantitativa, pois une a observação das rotinas de uso das fresadoras à medição e ao processamento de grandezas elétricas. Quanto aos objetivos, tem caráter exploratório e explicativo, buscando diagnosticar o comportamento do equipamento e relacionar as variações de corrente, tensão e frequência com o estado da máquina.

A pesquisa bibliográfica deu a base teórica do estudo. Foram priorizados artigos recentes, de periódicos e eventos reconhecidos, que tratassem de IIoT, sistemas embarcados, sensoriamento elétrico e TinyML. A Tabela 1 resume as principais pesquisas e o papel de cada uma no trabalho.

Tabela 1 – Síntese da pesquisa bibliográfica

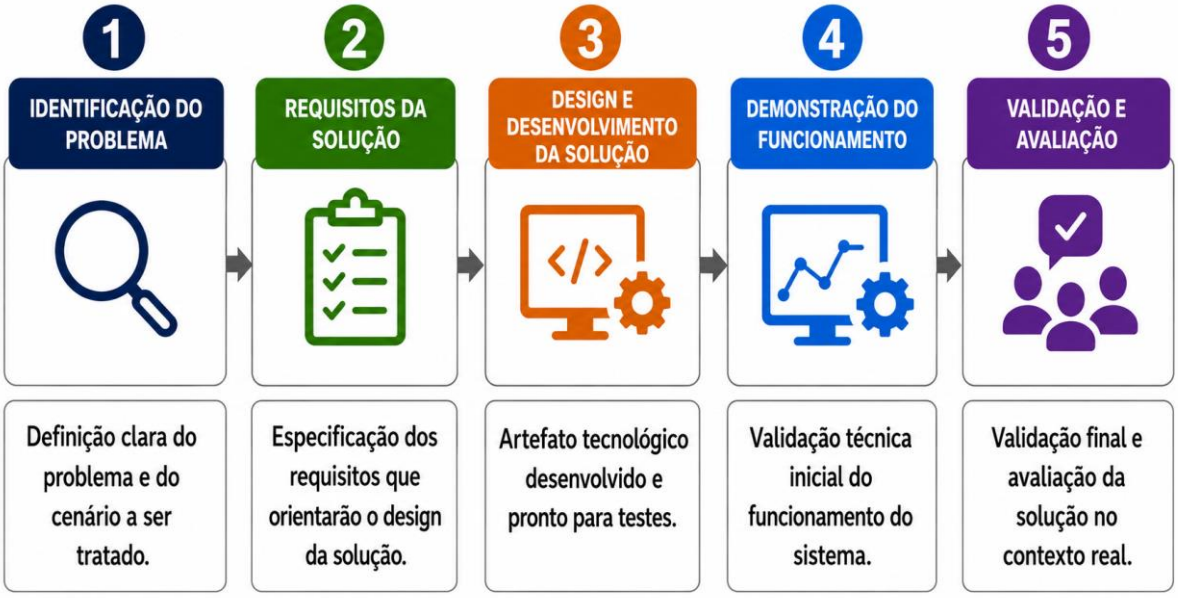
Autor (ano)	Tema	Contribuição para o trabalho
Khang *et al.* (2024)	IIoT na Indústria 4.0	Conceitos de IIoT e monitoramento (2.1)
Lopes, Ruggero e Okano (2026); Okano *et al.* (2026)	Convergência OT/IT	Contexto das PMEs e integração de dados (1 e 2.1)
Souza et al. (2024)	Transformação digital na manutenção de máquinas com DSR	Recorrência do problema informacional nas empresas (1)
Lopes, Mendes e Mario (2017)	Sistema ciberfísico com aquisição de dados em nuvem	Aquisição no chão de fábrica e armazenamento remoto (2.1)
Hercog *et al.* (2023)	Dispositivos IoT com ESP32	Escolha do ESP32, Wi-Fi e MQTT (2.1 e 2.2)
Lopes et al. (2024)	Avaliação de plataformas IoT por inovação frugal	Critérios para a escolha do microcontrolador (2.2)
Yasa *et al.* (2023)	Medição de energia com PZEM-004T	Escolha do sensor (2.2)
De las Morenas, Moya-Fernández e López-Gómez (2023)	Aprendizado de máquina na borda para diagnóstico de motores	Uso da corrente como indicador de estado (2.2)
Abadade *et al.* (2023); David *et al.* (2021); Elhanashi *et al.* (2024)	TinyML	Separação entre treino e inferência no ESP32 (2.3)
Okano *et al.* (2025)	IA embarcada na inspeção industrial	Referência de aplicação de IA na borda (2.3)
Peffers *et al.* (2007)	Design Science Research	Estrutura metodológica (3)
Brooke (1996); Bangor,	Avaliação com usuários (SUS e	Instrumentos e critérios de avaliação (3.5 e

Kortum e Miller (2009); Basili, Caldiera e Rombach (1994)	GQM)	4.5.3)
Peacefair ([20--]); WEG (2026); Schmersal (2023)	Documentação técnica do sensor, do motor e do inversor	Especificações e limites de medição (2.2, 4.1 e 4.5.1)

Fonte: Autores (2026)

O DSR é indicado para pesquisas que criam artefatos para resolver problemas reais. Segundo Peffers *et al.* (2007), o método passa pela identificação do problema, definição dos objetivos da solução, projeto e desenvolvimento, demonstração, avaliação e comunicação dos resultados. Neste trabalho, as cinco primeiras etapas foram aplicadas como mostra a Figura 1. Os tópicos a seguir descrevem os procedimentos executados em cada etapa; os resultados obtidos são apresentados na seção 4.

Figura 1 – Etapas do DSR aplicadas ao projeto



Fonte: Adaptado de Peffers et al. (2007)

A etapa de comunicação é materializada neste trabalho. As alterações introduzidas durante a execução, incluindo o limiar de sinalização e o reposicionamento do sensor, são registradas separadamente dos requisitos originalmente planejados.

3.1 Identificação do problema

A primeira etapa consistiu em visitas técnicas à AMJ Máquinas e Ferramentas, com observação da operação e entrevistas com o proprietário e os operadores. O objetivo foi verificar se existia algum tipo de monitoramento nas

fresadoras, como os registros eram feitos e quais problemas a falta de dados provocava na operação e na manutenção. A Figura 2 mostra a fresadora escolhida para o estudo.

Figura 2 – Fresadora CNC MH500 estudada



Fonte: Autores (2026)

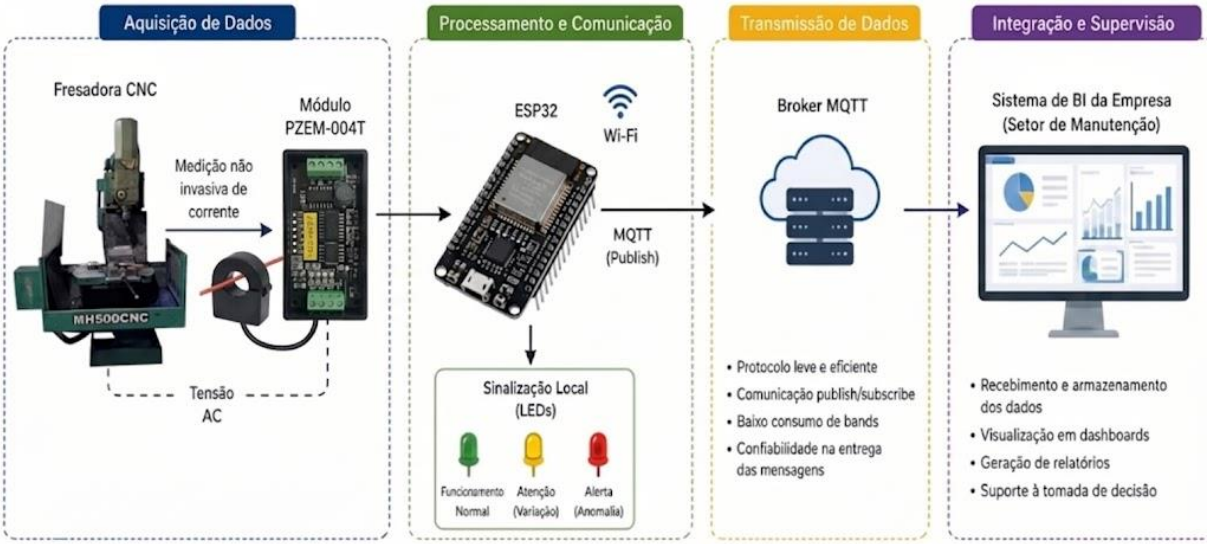
3.2 Definição dos requisitos

A partir do problema, foram definidos os requisitos técnicos e operacionais da solução, considerando as limitações do ambiente fabril, a integração com os sistemas da empresa e o uso de componentes de baixo custo. Os requisitos originalmente planejados foram:

- Identificar o estado de operação da fresadora pelas variáveis elétricas e alertar quando a máquina sair da condição normal, sem alterar o circuito de potência;
- Transmitir os dados por Wi-Fi, usando MQTT, para um *broker* e daí para um painel de BI;
- Classificar o estado da máquina no próprio dispositivo com TinyML;
- Ter instalação simples, baixo custo, fácil manutenção, operação contínua e sinalização visual por LEDs.

A Figura 3 resume a arquitetura prevista para atender a esses requisitos.

Figura 3 – Arquitetura prevista para o artefato



Fonte: Autores (2026)

3.3 Projeto e desenvolvimento

Nesta etapa foram definidos a montagem eletrônica, a lógica de aquisição dos sinais e a comunicação entre o dispositivo e os sistemas de supervisão. O artefato foi composto por fonte de alimentação, disjuntor de proteção, ESP32, PZEM-004T e um circuito de LEDs, alojados em uma caixa de proteção, conforme a Figura 4. O desenvolvimento foi dividido em seis frentes: hardware, aquisição dos dados, comunicação, preparação dos dados, treinamento do modelo e inferência no ESP32.

Figura 4 – Componentes previstos para o artefato



Fonte: Autores (2026)

3.4 Demonstração

A demonstração ocorreu em duas fases. Na primeira, em ambiente controlado, foram verificados a leitura do sensor, o envio dos dados, o painel e o banco de dados, além dos primeiros testes com TinyML. Na segunda, o artefato foi instalado na fresadora escolhida anteriormente para coletar dados de operação.

3.5 Avaliação

A avaliação teve três frentes. A primeira comparou as correntes medidas com os valores da folha de dados do motor e com uma medição independente feita com alicate amperímetro. A segunda mediu o desempenho do modelo em leituras que ele não viu no treino. A terceira avaliou a solução com os usuários da empresa, por meio da *System Usability Scale* (SUS), um questionário padronizado de dez itens sobre usabilidade (BROOKE, 1996), e do método *Goal Question Metric* (GQM), que verifica se os objetivos foram alcançados a partir de perguntas e métricas definidas para cada objetivo (BASILI; CALDIERA; ROMBACH, 1994). Para o GQM, foram aplicadas sete perguntas, cinco fechadas e duas abertas.

4 RESULTADOS E DISCUSSÕES

Esta seção segue a mesma ordem das etapas do DSR descritas na metodologia e apresenta o que foi encontrado e construído em cada uma delas, desde as visitas à empresa até a avaliação do artefato instalado na fresadora.

4.1 Identificação do problema

Nas visitas técnicas, o proprietário confirmou que a empresa não tinha nenhum sistema para medir o consumo de energia das fresadoras. Sem esse dado, ele não sabia quanto cada máquina gastava e o custo da hora-máquina era estimado. Também não havia controle do estado de operação das máquinas nem histórico de falhas.

Os operadores relataram desarmes frequentes de uma das fresadoras e aquecimento do motor principal. Na inspeção, verificou-se que esse motor é acionado por um inversor de frequência, conforme a Figura 5. Isso significa que a velocidade do eixo é variável e que o motor pode estar recebendo uma frequência diferente dos 60 Hz para os quais foi projetado.

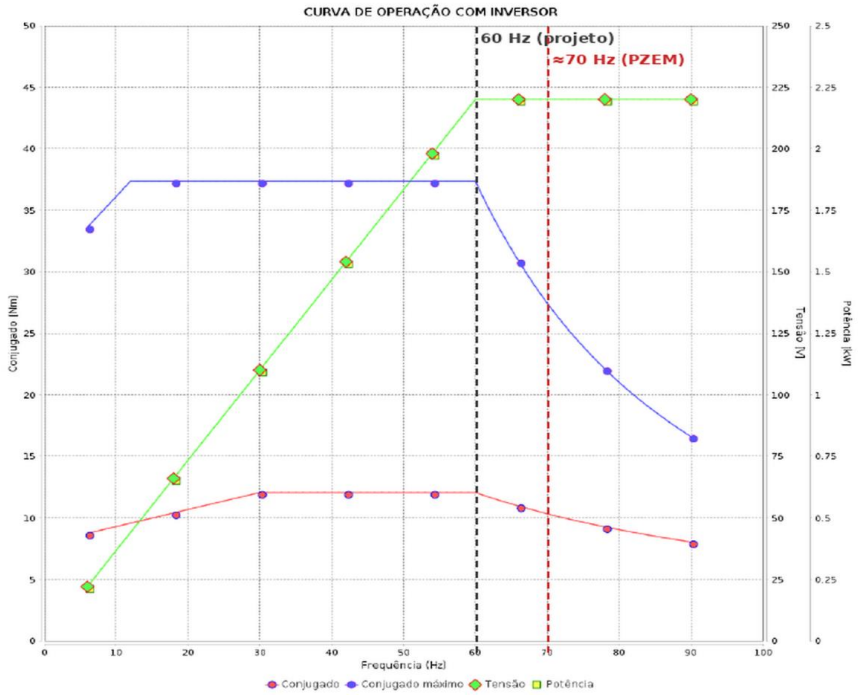
Figura 5 – Motor principal da fresadora (a) e inversor de frequência que o aciona (b)



Fonte: Autores (2026)

A folha de dados do motor, um WEG W22 IR3 Premium de 3 cv e 4 polos, informa os valores nominais para três tensões de ligação e um fator de serviço de 1,25 (WEG, 2026); na fresadora estudada, o motor é alimentado em 380 V. Esses valores, apresentados mais adiante na Tabela 13, foram a referência para interpretar as medições. Para operação com inversor, o fabricante fornece a curva da Figura 6: até 60 Hz o torque é constante e, acima disso, o motor entra na região de enfraquecimento de campo, em que o torque máximo cai.

Figura 6 – Curva de operação do motor com inversor e frequência indicada pelo PZEM-004T



Fonte: WEG (2026, p. 5), com anotação dos autores

Nota: a marcação de aproximadamente 70 Hz representa uma indicação exploratória do PZEM-004T na campanha inicial, obtida fora das condições nominais do instrumento; não corresponde à frequência do motor confirmada metrologicamente.

Durante a campanha inicial, o sistema apresentou leituras de frequência próximas de 70 Hz. Entretanto, como o ponto de instalação estava localizado após o inversor e fora das condições nominais do instrumento utilizado, tal valor foi tratado como indicação preliminar, não como medição confirmatória da frequência fundamental fornecida ao motor. A eventual associação com aquecimento e desarmes constitui hipótese técnica a ser investigada por meio dos parâmetros, histórico de falhas e medições compatíveis com o acionamento por inversor. O inversor Praxi 20 calcula internamente um modelo térmico do motor e guarda o histórico de falhas (SCHMERSAL, 2023), registros que permitem essa investigação.

4.2 Requisitos da solução

A Tabela 2 retoma os requisitos definidos no item 3.2 e mostra como cada um foi atendido.

Tabela 2 – Requisitos previstos e forma de atendimento

Requisito (item 3.2)	Como foi atendido
Identificar o estado de operação e alertar anomalias	MLP embarcada (PARADA, VAZIO, USINANDO) e limiar fixo de corrente (ACIMA DO PADRÃO OBSERVADO)
Não alterar o circuito de potência	PZEM-004T com transformador de corrente de núcleo

	aberto
Comunicação por Wi-Fi e MQTT	ESP32 publicando no broker HiveMQ
Integração com BI	Histórico no Google Sheets (Apps Script) e painel no Power BI
TinyML	MLP 6→8→4→3 com 107 parâmetros, treinada no computador e executada no ESP32
Baixo custo e instalação simples	Fonte, disjuntor, ESP32, PZEM-004T e LEDs; soma dos itens cotados de R$ 289,07 (Tabela 4)
Sinalização visual	Sete LEDs indicando o estado da máquina e a faixa de corrente (Tabela 9)
Condição de alimentação do motor (requisito novo)	Leitura exploratória de tensão e frequência pelo PZEM-004T; verificação metrológica não concluída no ponto de medição inicial. Situação: parcialmente avaliado

Fonte: Autores (2026)

Dois requisitos mudaram durante o projeto. A proposta inicial previa apenas os estados normal e anormal, mas a análise dos dados reais mostrou que era possível distinguir quatro: PARADA, VAZIO, USINANDO e ACIMA DO PADRÃO OBSERVADO. Os três primeiros são reconhecidos pela rede neural; o último, que apareceu pouco na coleta, é tratado por limiar fixo de corrente no firmware. A fronteira de 4 A entre vazio e usinagem foi observada na própria máquina, e o limiar de corrente acima do padrão observado, de 5,3 A, corresponde a cerca de 1,11 vez a corrente nominal do motor na ligação em 380 V, de 4,78 A. Além disso, como o motor é acionado por inversor, a interpretação da corrente passou a exigir o acompanhamento da frequência de alimentação, o que se tornou um requisito novo.

Para evitar que a verificação dos requisitos se restrinja à confirmação da implementação, cada requisito foi associado a um procedimento de teste, um critério de aceitação e uma evidência registrada, conforme a Tabela 3. Os requisitos sem medição quantitativa suficiente foram classificados como parcialmente avaliados ou não avaliados, não sendo considerados integralmente validados. A periodicidade e a continuidade dos registros foram estimadas a partir do histórico da planilha (item 4.3.1); a latência ponta a ponta e o desempenho em cada estado não foram medidos, e o custo foi discriminado por item com valores de referência de mercado (Tabela 4).

Tabela 3 – Matriz de rastreabilidade dos requisitos

Requisito	Critério de aceitação	Método e evidência	Situação
Identificar o estado de operação (PARADA, VAZIO, USINANDO)	Concordância com rótulo de referência independente	Teste em blocos com 304 leituras (99,7%) e teste com dias distintos (98,7%), com métricas por classe (Tabela 14); rótulos baseados na corrente (item 4.5.2)	Parcialmente avaliado
Sinalizar corrente acima do padrão observado	LED 7 aceso com corrente a partir de 5,3 A	Regra I ≥ 5,3 A no firmware v25, com precedência sobre a MLP, e teste de mesa do código nos limites (Tabela 10); 20 leituras acima de 5,3 A na coleta; acionamento do LED em campo não registrado	Parcialmente avaliado
Não alterar o circuito de potência	Instalação sem modificação do circuito de potência	Transformador de corrente de núcleo aberto; inspeção da instalação (Figura 14)	Verificado
Comunicação por Wi-Fi e MQTT	Leituras publicadas e registradas sem perda	Leituras gravadas no Google Sheets; intervalo mediano de 11 s (setembro) e 10 s (outubro); cobertura do registro de 56% e 79% em relação ao intervalo nominal de 10 s (Tabela 5); perda de mensagens MQTT e latência ponta a ponta não medidas	Parcialmente avaliado
Integração com BI	Registros disponíveis no painel com periodicidade definida	Painel no Power BI (Figura 9); periodicidade de atualização não registrada	Parcialmente avaliado
TinyML no dispositivo	Inferência executada no ESP32	MLP de 107 parâmetros implementada no firmware v25 (item 4.3.4); nos registros de setembro e outubro, as leituras constam como não classificadas pelo dispositivo	Parcialmente avaliado
Baixo custo e instalação simples	Custo discriminado por componente	Lista de materiais com valores de referência de 03/11/2026 (Tabela 4): R$ 289,07 nos itens cotados; conversor CA-CC e fiação não cotados; sem notas de aquisição	Parcialmente avaliado
Operação contínua	Tempo de operação sem interrupção	Maior sessão sem pausa acima de 5 min: 1,7 h em setembro e 12,7 h em outubro (Tabela 5)	Parcialmente avaliado
Sinalização visual por LEDs	LED correspondente a cada estado e compreendido pelos usuários	Gabarito da Tabela 9 e pergunta Q2 do GQM (média 4,00)	Parcialmente avaliado
Condição de alimentação do motor (requisito novo)	Frequência e tensão medidas com instrumento compatível	Indicação exploratória do PZEM-004T: cerca de 70 Hz na saída do inversor (setembro) e 60 Hz após o disjuntor geral (outubro), sem instrumento de referência	Parcialmente avaliado

Fonte: Autores (2026)

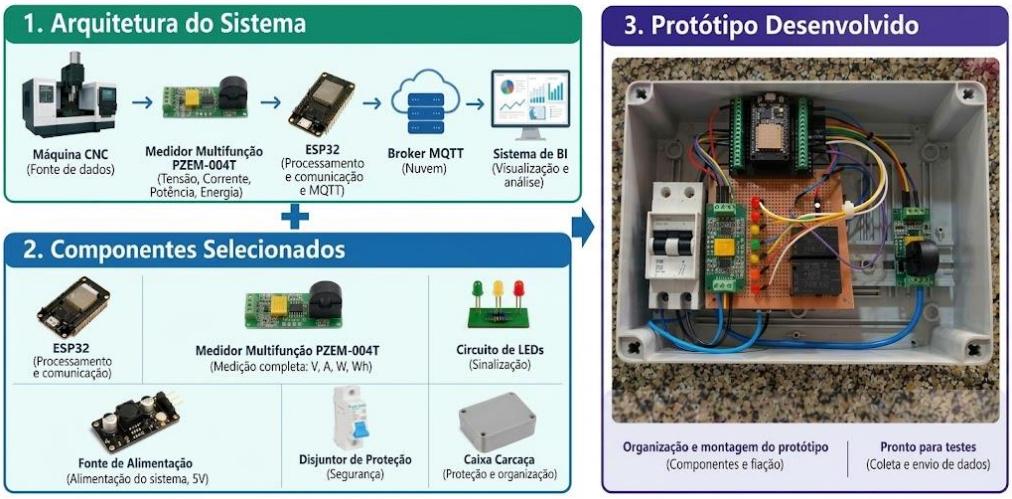
4.3 Desenvolvimento da solução

4.3.1 Hardware, aquisição e comunicação

O artefato reúne fonte, disjuntor de proteção, ESP32 DevKit V1, PZEM-004T v3.0 e um circuito de LEDs em uma caixa de proteção, conforme a Figura 7. A

instalação não exigiu mudanças no circuito de potência da fresadora. Na campanha de 25 a 29 de setembro de 2026, o transformador de corrente (TC) do PZEM-004T foi instalado em uma das fases de saída do inversor, que alimentam o motor, e os terminais de tensão foram ligados a duas fases desse mesmo circuito. A partir de 5 de outubro de 2026, apenas a derivação de tensão foi transferida para duas fases após o disjuntor geral da máquina, antes do inversor; o TC permaneceu na mesma fase de saída do inversor.

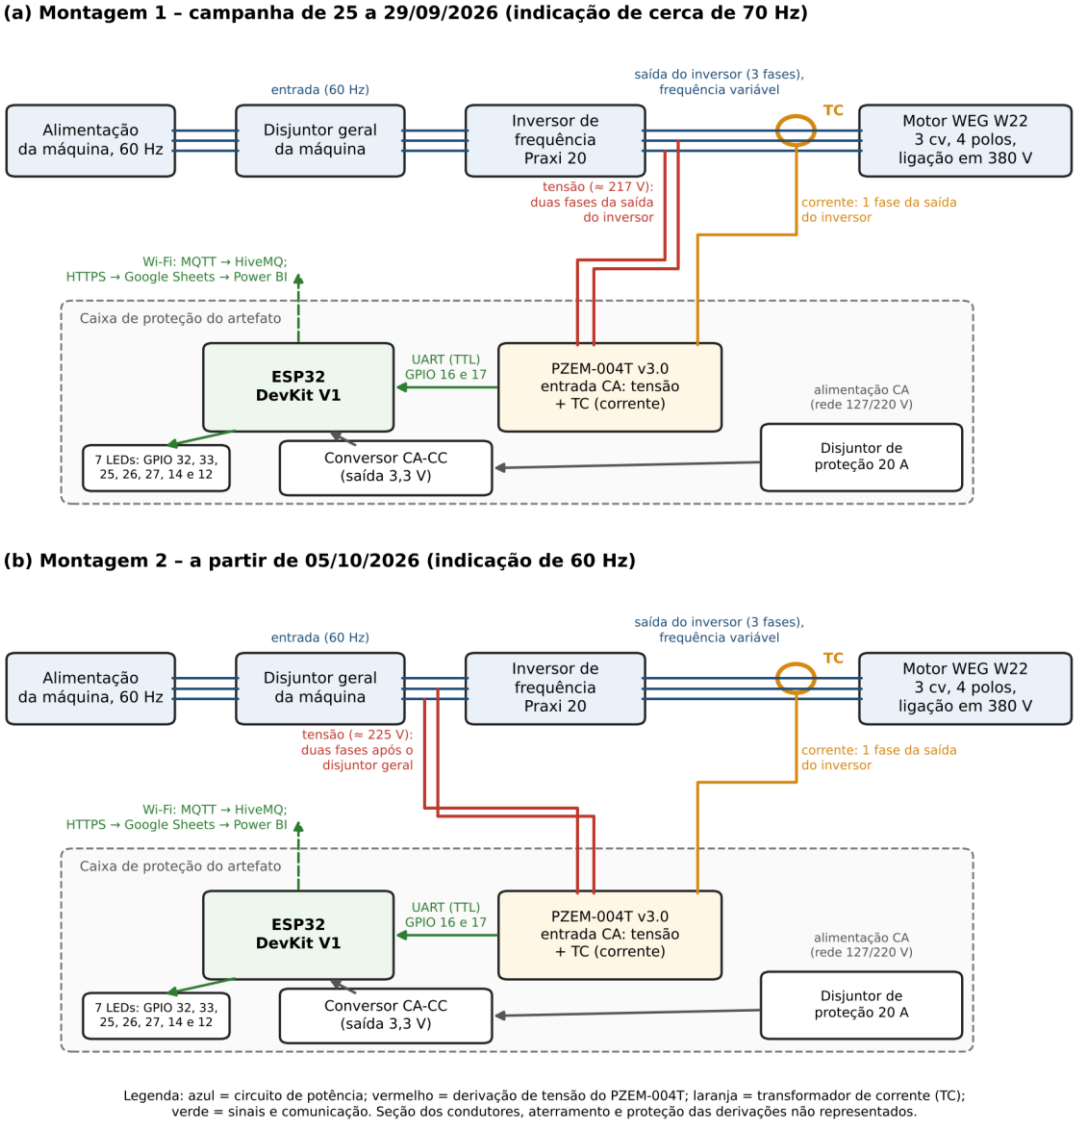
Figura 7 – Arquitetura, componentes e protótipo do artefato



Fonte: Autores (2026)

A Figura 8 apresenta o diagrama das conexões efetivamente utilizadas no protótipo, com os pontos de aquisição de corrente e tensão e os circuitos de alimentação e proteção do artefato. O reposicionamento realizado em outubro é identificado separadamente, pois modifica as grandezas observadas e limita a comparação direta com a campanha inicial.

Figura 8 – Diagrama de conexões do protótipo nas duas montagens



Fonte: Autores (2026), com base na montagem e nos registros da aba Histórico

O diagrama da Figura 8 foi elaborado pelos autores a partir da montagem, das informações do grupo e dos registros da aba Histórico, nos quais a mudança de arranjo é identificada pela frequência indicada pelo PZEM-004T: mediana de 69,9 Hz em todos os dias de setembro e de 60,0 Hz em todos os dias de outubro. Os terminais de tensão do PZEM-004T foram ligados entre duas fases, cada uma com 127 V em relação ao neutro, o que corresponde a cerca de 220 V entre fases e é coerente com as indicações de cerca de 217 V em setembro e de 225 V em outubro, dentro da faixa de 80 a 260 V do medidor; essa tensão não corresponde à alimentação de 380 V do motor. A comunicação entre o PZEM-004T e o ESP32 usa a interface serial nos pinos GPIO 16 e 17, e o ESP32 é alimentado por um conversor

CA-CC com saída de 3,3 V, ligado à rede de 127/220 V e protegido por um disjuntor de 20 A.

As campanhas de setembro e outubro utilizaram, portanto, pontos de aquisição de tensão distintos, com o TC no mesmo ponto. Em setembro, corrente e tensão foram obtidas entre o inversor e o motor; em outubro, a corrente continuou sendo obtida em uma fase de saída do inversor, mas a tensão passou a ser obtida no alimentador geral da máquina, antes do inversor. Em consequência, a corrente das duas campanhas refere-se ao mesmo condutor, enquanto tensão, frequência, potência, fator de potência e energia não foram tratados como diretamente equivalentes. Em outubro, a potência e o fator de potência calculados pelo PZEM-004T combinam a tensão da rede com a corrente de saída do inversor, que têm frequências diferentes, e por isso não representam a potência do motor: nas leituras com a máquina ligada, a mediana da potência indicada foi de 1,5 W e a do fator de potência, de 0,00. Além disso, como o PZEM-004T é alimentado pela própria entrada de tensão, em setembro ele só registrava dados quando havia tensão na saída do inversor, o que explica o pequeno número de leituras de máquina parada (0,4% das leituras válidas); em outubro, com a tensão tomada antes do inversor, passou a haver registro também com o motor parado (80% das leituras). Os limites de decisão da primeira configuração, embora aplicados à corrente medida no mesmo ponto, exigem nova validação para a segunda, e nenhum novo limiar foi validado até esta versão.

O ESP32 foi programado para ler tensão, corrente, potência, fator de potência, frequência e energia a cada 10 segundos. As leituras são publicadas por MQTT no broker HiveMQ e enviadas pelo próprio ESP32, por requisição HTTPS, a um Apps Script que as grava em uma planilha do Google Sheets; os registros da planilha são exibidos em um painel no Power BI (Figura 9), e as suas exportações em CSV alimentam o treinamento do modelo.

Segundo o código-fonte do firmware v25, a conexão com o broker usa TLS na porta 8883, com autenticação por usuário e senha, mas sem validação do certificado do servidor; as mensagens são publicadas com QoS 0 e sem retenção, e, se a conexão estiver perdida, o dispositivo faz até dez tentativas de reconexão, com intervalo de 2 s, antes da publicação. Na inicialização, o Wi-Fi tem cerca de 15 s para conectar e, se não conectar, o ESP32 é reiniciado. As leituras não são

armazenadas para nova publicação MQTT; as destinadas à planilha são enviadas em grupos de três, a cada 30 s, e mantidas em memória, até o limite de 12, enquanto não houver Wi-Fi, mas uma requisição que falhe não é repetida. As credenciais de acesso à rede e aos serviços foram omitidas deste trabalho.

Figura 9 – Painel de acompanhamento no Power BI



Fonte: Autores (2026)

O custo direto de hardware foi estimado por meio da lista de materiais da Tabela 4, composta pelos componentes efetivamente empregados, com valores de referência consultados em 3 de novembro de 2026 em lojas on-line (Mercado Livre, MakerHero, Santil, Raisa e Eletrogate). Os componentes foram adquiridos no Mercado Livre, mas os valores da tabela são cotações na data indicada, e não registros de aquisição. A soma dos itens cotados é de R$ 289,07, coerente com a estimativa de cerca de R$ 300,00; não foram cotados o conversor CA-CC de 3,3 V, a placa de circuito, os bornes e os condutores, e os LEDs e resistores são vendidos em embalagens com mais unidades do que as utilizadas. A estimativa não inclui mão de obra de montagem e instalação, serviços de eletricista, assinaturas de serviços em nuvem, licenças de software, rede de comunicação nem manutenção, não sendo equivalente ao custo total de implantação industrial.

Tabela 4 – Lista de materiais do protótipo

Item	Especificação	Qtd.	Valor de referência (R$)	Loja
ESP32 DevKit V1	Placa ESP32 WROOM-32 com Wi-Fi e Bluetooth	1	63,90	Mercado Livre
PZEM-004T v3.0 com TC	Medidor de tensão, corrente, potência, frequência, fator de potência e energia; TC de núcleo aberto incluído	1	46,53	Mercado Livre

Conversor de nível lógico	3,3–5 V, bidirecional, 4 canais	1	3,70	MakerHero
Disjuntor de proteção	Bipolar, 20 A, curva C	1	34,60	Santil
LEDs	RGB de alto brilho, pacote com 5 unidades	2 pacotes	23,94	Raisa
Resistores	Kit com 525 resistores de 17 valores	1 kit	47,40	Eletrogate
Caixa de proteção	250 × 160 × 120 mm	1	69,00	Mercado Livre
Conversor CA-CC	Entrada 127/220 V; saída 3,3 V	1	Não cotado	—
Placa de circuito, bornes e condutores	Não documentados	1 conjunto	Não cotado	—
Total dos itens cotados			289,07	

Fonte: Autores (2026)

A periodicidade efetiva foi estimada pelo intervalo entre leituras consecutivas registradas na aba Histórico da planilha, após a remoção de registros duplicados (Tabela 5). Na campanha de setembro, o intervalo mediano foi de 11 s e 77% dos intervalos ficaram entre 10 e 30 s; as leituras se distribuíram em 44 sessões separadas por pausas de mais de 5 minutos, a maior delas com 1,7 h, e a cobertura do registro, calculada com referência ao intervalo nominal de 10 s, foi de 56% nessas sessões. Na campanha de outubro, com a tensão tomada após o disjuntor geral, o intervalo mediano caiu para 10 s, a maior sessão contínua chegou a 12,7 h, entre 5 e 6 de outubro, e a cobertura atingiu 79%. Esses percentuais não representam perdas do MQTT, pois a planilha recebe as leituras diretamente do ESP32, e não pelo broker; como não havia numeração sequencial das leituras nem registro simultâneo de envio e recebimento, não é possível separar falha de envio, reconexão do Wi-Fi e atraso na gravação, e o intervalo entre leituras indica a periodicidade efetiva do registro, mas não a latência ponta a ponta, que continua sem medição.

Tabela 5 – Periodicidade efetiva do registro e ponto de medição em cada campanha

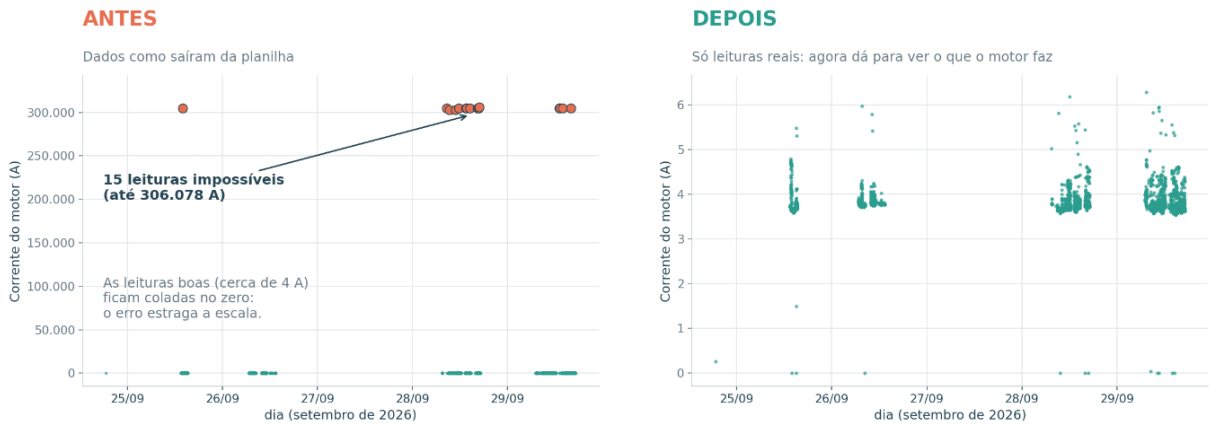
Medida	Setembro (25 a 29/09/2026)	Outubro (05 a 07/10/2026)
Ponto de medição	Corrente e tensão na saída do inversor	Corrente na saída do inversor; tensão após o disjuntor geral
Frequência e tensão indicadas (medianas)	69,9 Hz; 217,2 V	60,0 Hz; 225,5 V
Leituras únicas registradas	3.016	6.106
Leituras com corrente abaixo de 0,5 A	0,4%	80%
Intervalo mediano entre leituras	11 s	10 s
Percentil 90 do intervalo, dentro das sessões	30 s	17 s
Sessões (pausas acima de 5 min)	44	8
Maior sessão contínua	1,7 h	12,7 h
Cobertura do registro (referência: 10 s)	56%	79%

Fonte: Autores (2026), com dados da aba Histórico da planilha do projeto

4.3.2 Preparação dos dados

A coleta na fresadora ocorreu entre 25 e 29 de setembro de 2026. Antes do treino, os dados passaram por duas etapas. Na primeira, foram retirados os erros do sensor: 15 leituras fisicamente impossíveis, com valores de até 306.078 A, e 10 leituras muito diferentes das demais de mesma condição, identificadas pelo desvio absoluto mediano (MAD). O MAD usa a mediana, que quase não muda com valores extremos, e descarta a leitura quando $0{,}6745 \cdot |x - \text{mediana}|/\text{MAD} > 3{,}5$. Ele foi aplicado separadamente às classes VAZIO e USINANDO, para que a usinagem não fosse tratada como anomalia (Figura 10). As 20 leituras acima de 5,3 A ficaram fora do treino, porque a corrente acima do padrão observado é tratada por limiar. O critério MAD foi aplicado sobre todas as leituras de cada classe antes da partição, apenas para remover leituras, e os seus parâmetros não são usados pelo modelo; repetido com a mediana e o MAD estimados somente nas leituras atribuídas ao treino, o critério removeu as mesmas 10 leituras. Restaram 2.613 amostras candidatas, conforme o fluxo da Tabela 6.

Figura 10 – Remoção das leituras impossíveis e atípicas



Fonte: Autores (2026)

A Tabela 6 reúne o registro de rastreabilidade da amostra, desde as linhas exportadas da aba Histórico da planilha até a partição final. Entre 25 e 29 de setembro, a aba registra 3.705 linhas, das quais 689 repetem o dia 26 por terem sido exportadas duas vezes; restam 3.016 leituras únicas, sem coleta no dia 27. Após a remoção das 15 leituras impossíveis, ficam 3.001 leituras válidas. Dessas, 358 leituras do início de cada sequência contínua não tinham leituras anteriores suficientes para formar a janela de dez leituras, 20 foram segregadas por limiar e 10 foram removidas pelo MAD, restando 2.613 amostras candidatas. Dessas, 227 foram excluídas por sobreposição de janelas entre partições, resultando em 2.386 amostras efetivamente utilizadas no teste em blocos: 1.733 para treino, 349 para validação e 304 para teste. Há, portanto, dois níveis de exclusão: o primeiro, de limpeza e formação das janelas, define as amostras candidatas; o segundo, específico do teste em blocos, remove as janelas de fronteira. Os identificadores temporais e os critérios de exclusão devem ser preservados nas próximas coletas, para permitir a reprodução do tratamento e evitar que observações correlacionadas sejam indevidamente distribuídas entre os conjuntos.

Tabela 6 – Fluxo das leituras na preparação dos dados (25 a 29/09/2026; corrente e tensão na saída do inversor)

Etapa	Leituras	Observação
Linhas exportadas na aba Histórico	3.705	Período de 25 a 29/09/2026
Linhas duplicadas	689	Dia 26/09 exportado duas vezes
Leituras únicas	3.016	25/09: 319; 26/09: 689; 28/09: 912; 29/09: 1.096
Removidas por erro do sensor	15	Até 306.078 A; 1 em 25/09, 10 em 28/09 e 4 em 29/09
Leituras válidas	3.001	Ponto de partida do tratamento
Sem janela completa de dez leituras	358	Início de cada sequência contínua
Segregadas por limiar (acima de 5,3 A)	20	Tratadas por regra no firmware, fora da MLP
Removidas como atípicas (MAD)	10	Critério 0,6745·|x − mediana|/MAD > 3,5, aplicado a VAZIO e USINANDO
Amostras candidatas (após limpeza e formação das janelas)	2.613	PARADA 8; VAZIO 2.282; USINANDO 323. Por dia: 25/09, 286; 26/09, 622; 28/09, 758; 29/09, 947
Excluídas por sobreposição de janelas entre partições (teste em blocos)	227	Janela com leituras de outra partição. Por dia: 25/09, 18; 26/09, 56; 28/09, 54; 29/09, 99
Efetivamente particionadas (teste em blocos)	2.386	Treino, validação e teste: 1.733 + 349 + 304
Treino	1.733	PARADA 7; VAZIO 1.476; USINANDO 250. Por dia: 25/09, 227; 26/09, 437; 28/09, 480; 29/09, 589
Validação	349	VAZIO 319; USINANDO 30. Por dia: 25/09, 41; 26/09, 47; 28/09, 138; 29/09, 123
Conjunto de teste	304	VAZIO 282; USINANDO 22; nenhuma leitura de PARADA. Por dia: 26/09, 82; 28/09, 86; 29/09, 136

Fonte: Autores (2026)

Na segunda etapa, as variáveis foram colocadas na mesma escala pelo *z-score*, $z = (x - \mu)/\sigma$, pois a potência, em torno de 750 W, é centenas de vezes maior que o fator de potência, em torno de 0,9, e dominaria o treino. A média e o desvio-padrão foram calculados apenas no conjunto de treino de cada ensaio; no firmware, ficam gravados a média e o desvio-padrão do treino do modelo embarcado, e a mesma conta é repetida a cada nova leitura. A Tabela 7 mostra as variáveis usadas e as descartadas.

Tabela 7 – Variáveis de entrada do modelo avaliado

Variável	Uso	Justificativa
Corrente (A)	Entrada	Medida direta da carga: cerca de 3,8 A em vazio e acima de 4 A cortando
Potência (W)	Entrada	Confirma o esforço do motor por outra grandeza
Fator de potência	Entrada	Cai com a carga (correlação de −0,93 com a corrente)
Variação da corrente	Entrada	Diferença entre leituras seguidas; revela início e fim do corte
Média da corrente (10 leituras)	Entrada	Suaviza ruído: um pico isolado não muda o estado
Desvio-padrão da corrente (10 leituras)	Entrada	Indica se o esforço está estável ou irregular
Tensão (V)	Descartada	Varia pouco (correlação de −0,22 com a corrente)

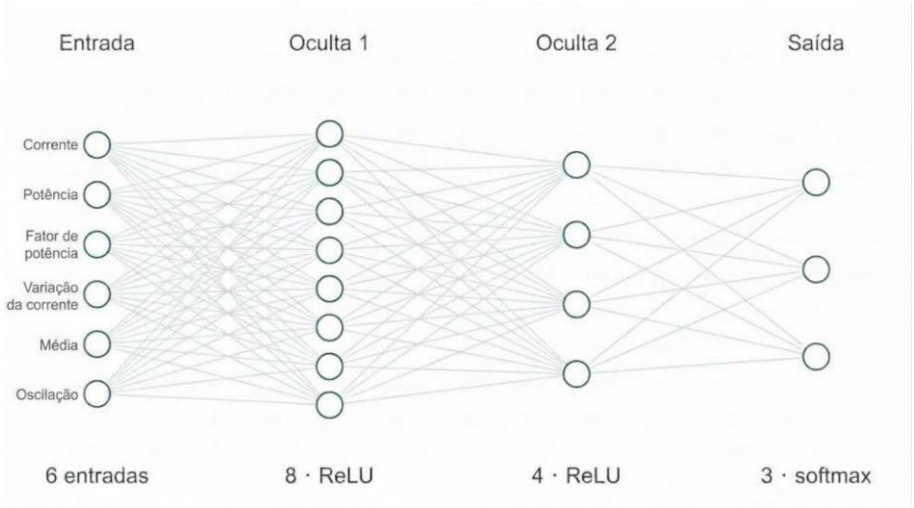
Frequência (Hz)	Descartada	Praticamente constante na coleta (indicação de cerca de 70 Hz)
Energia (kWh)	Descartada	Contador acumulado: mede tempo, não estado

Fonte: Autores (2026)

4.3.3 Treinamento do modelo

O modelo é uma MLP com estrutura 6→8→4→3 e 107 parâmetros treináveis, pequena o bastante para o ESP32 (Figura 11). As camadas ocultas usam ReLU e a camada de saída usa *softmax*, que entrega a probabilidade de cada estado: PARADA, VAZIO e USINANDO.

Figura 11 – Estrutura da rede neural MLP 6→8→4→3 avaliada nas Tabelas 14 e 15



Fonte: Autores (2026)

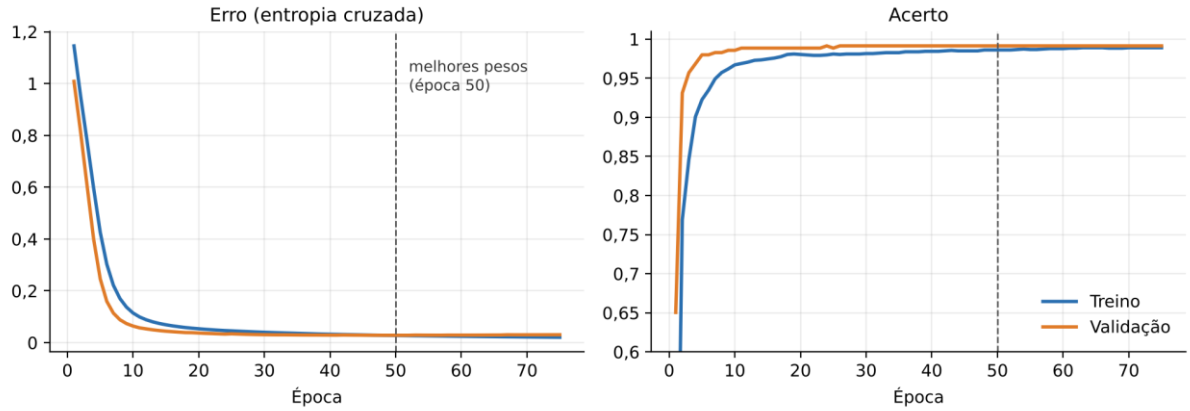
O treino foi feito em Python, com o otimizador Adam (taxa de aprendizado de 0,001), lotes de 32 leituras e entropia cruzada como função de perda. Para evitar o sobreajuste, o treino parava após 25 épocas sem melhora na validação, e eram mantidos os pesos da melhor época. No teste em blocos, os melhores pesos foram os da época 50, de 75 executadas. Antes do treino, a rede atribuía cerca de um terço de probabilidade a cada estado; ao final, o erro de validação foi de 0,029 e o acerto de validação, de 99,1% (Figura 12). As curvas de treino e de validação caminharam juntas, sinal de que a rede não estava apenas decorando os dados.

As divisões dos conjuntos respeitaram a ordem temporal das leituras, para que leituras quase iguais não caíssem em conjuntos diferentes. As variáveis da Tabela 7 foram calculadas em janelas de dez leituras dentro de cada sequência contínua, em que pausas acima de 5 minutos iniciam uma nova sequência. As leituras foram agrupadas em blocos de 50 leituras consecutivas, sorteados com semente 42 na proporção de 70% para treino, 15% para validação e 15% para teste,

e as 227 leituras cuja janela de dez leituras incluía observações de outra partição foram excluídas. A normalização foi calculada exclusivamente sobre o treino. A composição de cada conjunto, por classe e por data, está na Tabela 6. Uma versão preliminar do protocolo, que não separava as sequências contínuas nem excluía as janelas de fronteira, havia retido 2.173 leituras e obtido 99,7% de acerto no teste e 94,4% no teste com dias distintos; os resultados apresentados neste trabalho correspondem à versão final do protocolo.

No ensaio temporal, os registros dos dias 25 e 26 de setembro constituíram a base disponível para desenvolvimento e ajuste do modelo, e os dos dias 28 e 29 foram reservados para teste. Das 908 amostras candidatas de 25 e 26/09, as primeiras 85% em ordem cronológica formaram o treino (771: 3 PARADA, 696 VAZIO e 72 USINANDO), e as 15% finais, a partir de 26/09 às 10h34, a validação (137: 133 VAZIO e 4 USINANDO). A média e o desvio-padrão do z-score foram calculados somente no treino, a melhor época foi escolhida pela perda de validação, com a mesma parada antecipada (25 épocas sem melhora), e foram mantidos a arquitetura, a taxa de aprendizado, o tamanho de lote e a semente 42 do teste em blocos, sem busca de hiperparâmetros; a melhor época foi a 265, de 290 executadas. As 1.705 amostras de 28 e 29/09 (5 PARADA, 1.453 VAZIO e 247 USINANDO) não foram usadas no treinamento, na normalização nem na escolha da época. Como não houve coleta em 27/09, nenhuma janela do teste inclui leituras dos dias de desenvolvimento; entre treino e validação não foi aplicada exclusão de fronteira, e 9 janelas da validação incluem leituras do treino. A matriz de confusão correspondente está na Tabela 15.

Figura 12 – Curvas de erro e acerto no treinamento do modelo (teste em blocos, semente 42)



Fonte: Autores (2026)

O treinamento não exigiu servidor nem placa de vídeo dedicada à inteligência artificial. O desenvolvimento preliminar foi realizado no notebook descrito na Tabela 8, em Python 3.11 (IDLE) com TensorFlow/Keras, cujas versões exatas de biblioteca não foram registradas. O treinamento que originou os resultados finais das Tabelas 14 e 15 e das Figuras 12 e 18 foi executado com o script de reexecução do protocolo em Python 3.13.18, TensorFlow 2.21.0, NumPy 2.5.3, pandas 3.0.5 e scikit-learn 1.9.1, em ambiente Linux virtualizado em nuvem, apenas com processador, e foi concluído em poucos minutos. As versões foram obtidas do próprio ambiente de execução e registradas para permitir reprodução.

Tabela 8 – Ambientes do desenvolvimento preliminar e da execução final do modelo

Item	Desenvolvimento preliminar	Execução final (Tabelas 14 e 15)
Equipamento	Notebook Dell G7 7588	Ambiente Linux virtualizado em nuvem
Processador	Intel Core i7-8750H, 2,20 GHz	4 núcleos x86_64 virtuais
Memória RAM	16 GB, 2.667 MHz	15 GB
Placa de vídeo	NVIDIA GeForce GTX 1050 Ti (4 GB) e Intel UHD Graphics 630	Não utilizada
Sistema operacional	Windows 10 Pro, 64 bits (versão 22H2)	Linux 6.18, 64 bits
Python e bibliotecas	Python 3.11 (IDLE) com TensorFlow/Keras; versões das bibliotecas não registradas	Python 3.13.18; TensorFlow 2.21.0; NumPy 2.5.3; pandas 3.0.5; scikit-learn 1.9.1

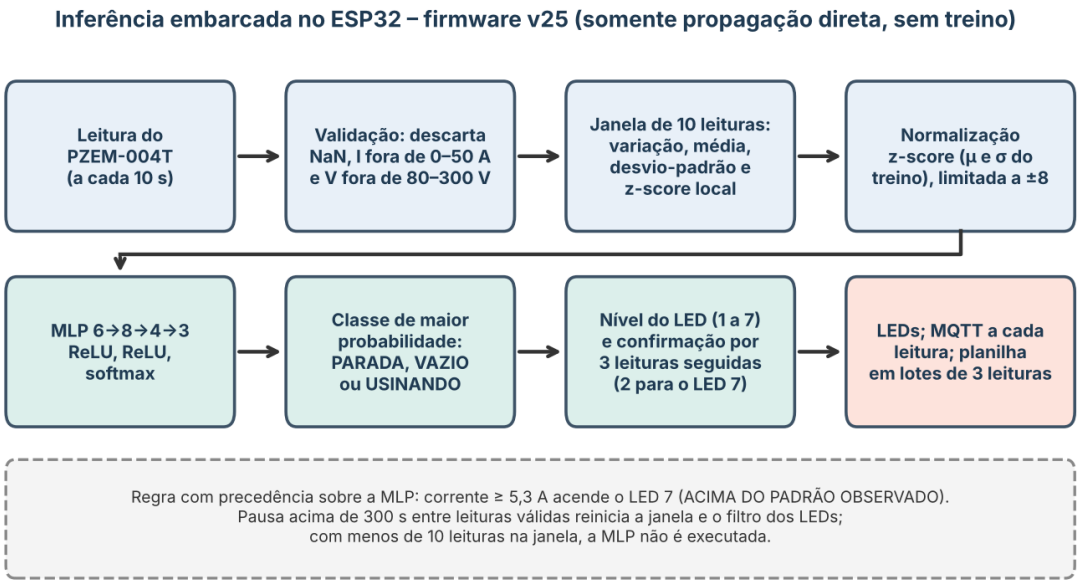
Fonte: Autores (2026)

4.3.4 Inferência no ESP32

Com o treino concluído, os pesos, os vieses e os parâmetros de normalização são copiados para o código do ESP32. Na versão mais recente do firmware fornecida pelo grupo, a v25, a rede embarcada tem a mesma estrutura 6→8→4→3, mas foi treinada depois, com dados da segunda montagem (item 4.6), e usa como entradas a corrente, a tensão, a variação da corrente, a média e o desvio-padrão da janela de dez leituras e o z-score da corrente na janela, no lugar da potência e do fator de potência da Tabela 7. Os resultados das Tabelas 14 e 15 referem-se, portanto, ao modelo do protocolo descrito nos itens 4.3.2 e 4.3.3, e não aos pesos gravados no firmware. Em operação (Figura 13), a cada leitura válida o dispositivo atualiza a janela, aplica o z-score, passa os seis valores pela rede e adota o estado de maior probabilidade; a corrente a partir de 5,3 A é verificada por limiar, com precedência sobre a rede. O resultado acende o LED correspondente, é publicado por MQTT e é enviado à planilha. Assim, a parte pesada do processamento fica no

computador e o microcontrolador apenas executa o modelo pronto, como prevê o TinyML (ABADADE et al., 2023; DAVID et al., 2021).

Figura 13 – Fluxo de inferência embarcada no ESP32 (firmware v25)



Fonte: Autores (2026)

O mecanismo embarcado combina classificação por MLP para os estados PARADA, VAZIO e USINANDO com uma regra de corrente para a sinalização de atenção. O estado definido por limiar não integra a saída de três classes da rede e, portanto, não deve ser contabilizado como acerto de inferência da MLP. Considerando a presença de apenas oito leituras de máquina parada retidas na coleta analisada, o desempenho dessa classe não pode ser considerado suficientemente caracterizado. Nos registros da planilha usados neste trabalho, de setembro e outubro, todas as leituras constam com nível “BRUTO” e estado “Leitura bruta”, ou seja, foram gravadas sem classificação pelo dispositivo; não há, portanto, registro em campo das classes atribuídas pelo ESP32.

Para que o operador acompanhe a máquina sem precisar abrir o painel, os sete LEDs do artefato, ligados aos pinos GPIO 32, 33, 25, 26, 27, 14 e 12, funcionam como um indicador visual em que apenas um LED fica aceso por vez. A Tabela 9, elaborada a partir do firmware v25, serve de gabarito para a leitura desse indicador: a classe vem da MLP e a corrente escolhe o LED dentro de VAZIO e de USINANDO.

Tabela 9 – Gabarito do indicador de LEDs

Critério de decisão	LED(s) e cor	Indicação	O que fazer
MLP: PARADA	LED 1, vermelho	Máquina desligada	Nenhuma ação
MLP: VAZIO, com I < 3,0 A	LED 2, laranja	Partida ou aceleração do motor	Nenhuma ação
MLP: VAZIO, com I ≥ 3,0 A	LED 3, amarelo	Máquina ligada em vazio, sem cortar	Verificar se a máquina deveria estar produzindo
MLP: USINANDO, com I < 4,43 A	LED 4, verde	Usinagem com menor esforço	Nenhuma ação
MLP: USINANDO, com 4,43 A ≤ I < 4,87 A	LED 5, amarelo	Usinagem com esforço maior	Acompanhar o corte
MLP: USINANDO, com I ≥ 4,87 A	LED 6, laranja	Usinagem com esforço elevado	Acompanhar o corte e conferir ferramenta e parâmetros
Limiar: I ≥ 5,3 A, com precedência sobre a MLP	LED 7, vermelho	Corrente acima do padrão observado	Conferir ferramenta e parâmetros e, se persistir, verificar o motor e o inversor

Fonte: Autores (2026)

A decisão embarcada ocorre em duas etapas: a MLP classifica cada leitura em PARADA, VAZIO ou USINANDO, e a regra de corrente acrescenta a sinalização ACIMA DO PADRÃO OBSERVADO. Os operadores relacionais dos rótulos usados no treino foram confirmados no script de treinamento, e a ordem de verificação, os operadores dos limiares, o filtro de mudança de LED e o comportamento após perda de sinal foram confirmados no código-fonte do firmware v25 (arquivo com SHA-256 iniciado por aaec487827bb), conforme a Tabela 10. Em teste de mesa, o código de decisão do firmware foi executado em computador, sem o PZEM-004T, com janelas de corrente constante e tensão de 225 V: correntes a partir de 5,30 A acenderam o LED 7, enquanto as fronteiras aprendidas pela rede ficaram em cerca de 0,58 A, entre PARADA e VAZIO, e de 3,97 A, entre VAZIO e USINANDO, e não exatamente nos limites de rotulagem de 0,5 e 4,0 A. O ensaio com o dispositivo e correntes de valor conhecido não foi realizado.

Tabela 10 – Especificação das regras de decisão

Elemento da decisão	Especificação	Origem e situação
Rótulo PARADA	I < 0,5 A	Confirmado no script de treinamento
Rótulo VAZIO	0,5 A ≤ I < 4,0 A	Confirmado no script de treinamento
Rótulo USINANDO	4,0 A ≤ I ≤ 5,3 A	Confirmado no script de treinamento
Leituras segregadas do treino	I > 5,3 A	Confirmado no script de treinamento

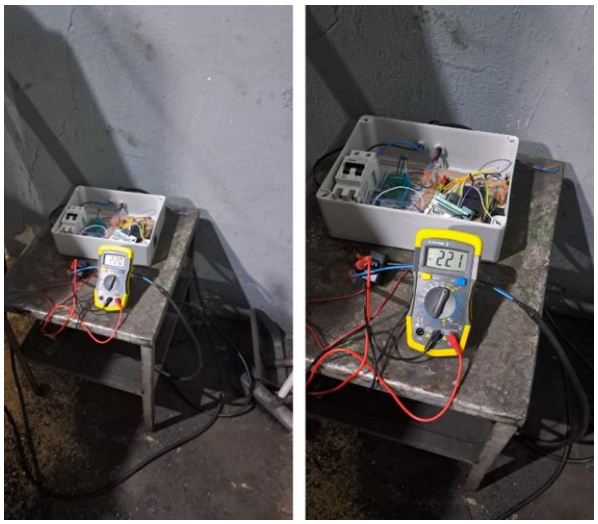
Histerese na rotulagem	Não utilizada	Confirmado no script de treinamento
Validação da leitura	Leitura descartada se algum valor for inválido, se I < 0 A ou I > 50 A, ou se V < 80 V ou V > 300 V	Confirmado no firmware v25
Janela de dez leituras	MLP executada somente com dez leituras na janela; pausa acima de 300 s entre leituras válidas reinicia a janela e apaga os LEDs até a nova indicação	Confirmado no firmware v25
Saída da MLP	Classe de maior probabilidade (softmax) entre PARADA, VAZIO e USINANDO; entradas normalizadas por z-score e limitadas a ±8	Confirmado no firmware v25
Limiar ACIMA DO PADRÃO OBSERVADO	I ≥ 5,3 A acende o LED 7; verificado antes da MLP, inclusive sem janela completa	Confirmado no firmware v25
LED dentro da classe	VAZIO: LED 2 se I < 3,0 A e LED 3 se I ≥ 3,0 A; USINANDO: LEDs 4, 5 e 6 nos terços de 4,0 a 5,3 A (limites de cerca de 4,43 e 4,87 A)	Confirmado no firmware v25
Filtro de mudança de LED	Novo LED exibido após 3 leituras seguidas com a mesma indicação (30 s), ou 2 leituras (20 s) para o LED 7; a primeira indicação é exibida diretamente	Confirmado no firmware v25
Perda de sinal do PZEM-004T	Leitura ignorada; os LEDs mantêm a última indicação e nada é publicado	Confirmado no firmware v25
Perda do Wi-Fi ou do broker	Sem armazenamento para o MQTT; até 12 leituras guardadas para a planilha; até 10 tentativas de reconexão ao broker	Confirmado no firmware v25
Limiar de 7,2 A	Não implementado	Confirmado no firmware v25
Teste nos limites de 0,5; 4,0 e 5,3 A	Teste de mesa do código: LED 7 a partir de 5,30 A; fronteiras da MLP em cerca de 0,58 e 3,97 A	Teste de mesa realizado; ensaio com o dispositivo pendente

Fonte: Autores (2026)

4.4 Demonstração

Na fase em ambiente controlado, foram verificados a leitura do sensor com cargas conhecidas, o envio dos dados, a planilha e o painel, além dos primeiros testes de TinyML. Em seguida, o artefato foi instalado em uma fresadora da AMJ (Figura 14), onde registrou leituras entre 25 e 29 de setembro de 2026.

Figura 14 – Artefato instalado na fresadora da AMJ



Fonte: Autores (2026)

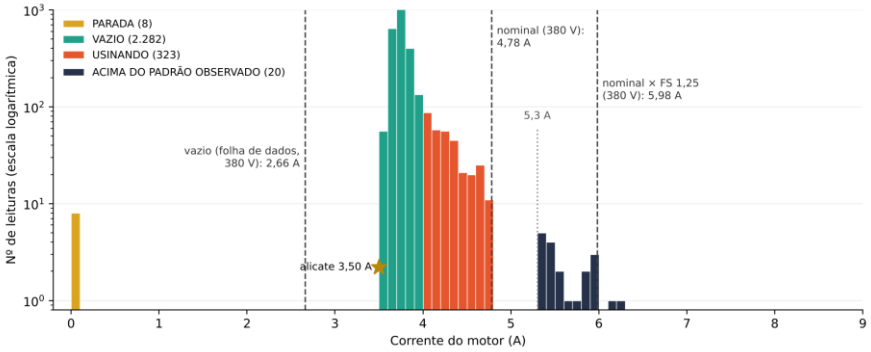
A Tabela 11 e a Figura 15 resumem as condições registradas. Quando a máquina corta material, a corrente sobe: a mediana passa de 3,75 A em vazio para 4,23 A durante a usinagem, cerca de 13% a mais, como se espera de um motor que recebe mais carga. A máquina parada apareceu em apenas oito leituras, e houve 20 leituras de corrente acima do padrão observado, entre 5,30 e 6,29 A. A tensão indicada na derivação do medidor ficou em torno de 217 V, e a frequência indicada pelo sensor ficou em torno de 70 Hz, valor tratado como indicação preliminar (item 4.1). Para um motor de quatro polos, 70 Hz corresponderiam a uma velocidade síncrona calculada de 2.100 rpm, contra 1.800 rpm a 60 Hz; a rotação mecânica do eixo não foi medida e depende do escorregamento.

Tabela 11 – Corrente medida pelo PZEM-004T em cada estado (25 a 29/09/2026; saída do inversor)

Estado	Leituras	Faixa de corrente	Mediana
PARADA	8	cerca de 0 A	—
VAZIO	2.282	3,53 a 4,00 A	3,75 A
USINANDO	323	4,00 a 4,79 A	4,23 A
ACIMA DO PADRÃO (> 5,3 A)	20	5,30 a 6,29 A	—

Fonte: Autores (2026)

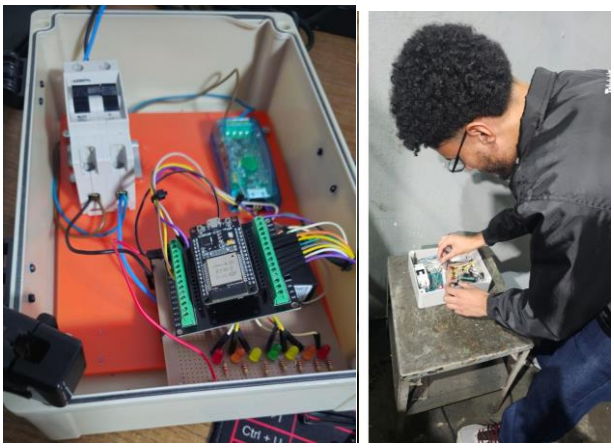
Figura 15 – Distribuição das leituras de corrente por estado (25 a 29/09/2026; saída do inversor)



Fonte: Autores (2026)

A Figura 16 registra a equipe durante a montagem do artefato e a sua instalação junto à fresadora.

Figura 16 – Montagem (a) e instalação (b) do artefato pela equipe



Fonte: Autores (2026)

Os dados elétricos também foram cruzados com o sistema de apontamento de produção da empresa. A Tabela 12 compara dois apontamentos seguidos da mesma ordem de serviço (OS 27270), feitos em 07/10/2026 na fresadora MAHO1, para a mesma peça (anelado) e a mesma operação (usinagem *blanc*). Nessa data, a tensão já era tomada após o disjuntor geral, enquanto a corrente continuava sendo medida na mesma fase de saída do inversor usada em setembro; por isso, foram usadas apenas a corrente e a tensão, e não a potência nem o fator de potência. Os tempos da Tabela 12 são tempos classificados, e não observados: cada leitura foi classificada pelo critério de corrente do projeto (I < 0,5 A, máquina parada; 0,5 A ≤ I < 4,0 A, ligada sem usinar; I ≥ 4,0 A, usinando), e o intervalo até a leitura seguinte, dentro da janela do apontamento, foi somado ao estado dessa leitura. A cobertura

corresponde ao tempo entre a primeira e a última leitura de cada apontamento, recalculado a partir da aba Histórico.

Tabela 12 – Comparativo elétrico entre dois apontamentos da OS 27270 (07/10/2026; corrente na saída do inversor e tensão após o disjuntor geral)

Medida	Apontamento 1 (14h31–14h51)	Apontamento 2 (14h51–15h12)
Tempo apontado (min)	20	21
Tempo coberto por leituras (min) e cobertura	19,8 (99%)	20,3 (96%)
Número de leituras	91	76
Intervalo mediano e máximo entre leituras (s)	11 e 37	14 e 60
Classificado como parada, I < 0,5 A (min)	3,6	4,9
Classificado como ligada sem usinar, 0,5 A ≤ I < 4,0 A (min)	14,9	14,9
Classificado como usinando, I ≥ 4,0 A (min)	1,3	0,5
Corrente média com a máquina ligada (A)	3,78	3,77
Corrente média nos picos, I ≥ 4,0 A (A)	4,51	4,64
Corrente máxima (A)	4,90	4,76
Tensão média (V)	221,9	222,7

Fonte: Autores (2026), com dados do sistema de apontamento da AMJ

Os dois apontamentos tiveram comportamento elétrico muito parecido: a corrente média com a máquina ligada variou menos de 0,5%, e os picos de usinagem ficaram entre 4,5 e 4,9 A, dentro da faixa de USINANDO da Tabela 11. O que mais chama a atenção é a divisão do tempo. Embora os 20 e 21 minutos tenham sido apontados como usinagem, cerca de três quartos desse período foram classificados como máquina ligada sem cortar, e a corrente de usinagem foi registrada em apenas 1,3 e 0,5 minuto. Parte dessa diferença vem do intervalo entre leituras, de 10 a 60 segundos, que não capta cortes curtos; por isso, esses valores indicam a distribuição dos estados classificados e não o tempo exato de corte.

A comparação com os apontamentos de produção foi conduzida de forma exploratória, mediante os registros disponíveis no período analisado, já com a tensão tomada no circuito geral da máquina. Embora a corrente tenha sido medida no mesmo condutor da coleta de setembro, as faixas de corrente adotadas na rotulagem original não foram revalidadas nessa configuração. A diferença entre tempos reportados e estados inferidos não pode ser atribuída exclusivamente a

falhas de apontamento, pois também depende da cobertura da aquisição, do novo ponto de sensoriamento da tensão e da validade dos limiares.

4.5 Avaliação

4.5.1 Medições comparadas à folha de dados

A Tabela 13 confronta as medições com a folha de dados do motor. Como o motor é alimentado em 380 V, a coluna de 380 V foi tomada como referência; a tensão de cerca de 217 V indicada pelo PZEM-004T corresponde à derivação ligada ao medidor (item 4.3.1), e não à tensão de linha do motor. Nessa comparação, a corrente em vazio medida, de 3,53 a 4,00 A, fica acima dos 2,66 A do fabricante (mediana 41% maior); a corrente durante a usinagem, de 4,00 a 4,79 A, aproxima-se da nominal, de 4,78 A; e as 20 leituras acima do padrão observado, de 5,30 a 6,29 A, superam a corrente nominal, e duas delas superam também a corrente nominal multiplicada pelo fator de serviço, de 5,98 A (Figura 15). Como os valores da folha de dados se referem à alimentação senoidal a 60 Hz, e as medições foram feitas na saída do inversor, com indicação de cerca de 70 Hz e fora da faixa especificada do sensor, essa comparação é indicativa.

Tabela 13 – Valores da folha de dados e valores medidos (motor ligado em 380 V)

Item	220 V	380 V	Medido (25 a 29/09/2026, saída do inversor)
Corrente nominal	8,25 A	4,78 A	—
Corrente a vazio	4,60 A	2,66 A	3,53 a 4,00 A (mediana 3,75 A; alicate 3,50 A)
Corrente nominal × fator de serviço (1,25)	10,3 A	5,98 A	—
Usinando	—	—	4,00 a 4,79 A (mediana 4,23 A)
Acima do padrão observado (20 leituras)	—	—	5,30 a 6,29 A
Tensão e frequência	220 V; 60 Hz	380 V; 60 Hz	cerca de 217 V na derivação do medidor; 70 Hz (indicação preliminar)

Fonte: WEG (2026, p. 1) e medições dos autores

O limiar de 5,3 A foi empregado nesta etapa como limite operacional de sinalização definido para o protótipo, sem equivalência demonstrada com condições de sobrecarga térmica do motor. A caracterização de sobrecarga requer confirmação da ligação elétrica, dos dados de placa, das condições de acionamento e das grandezas medidas com instrumento apropriado. Na referência de 380 V, esse limiar

corresponde a cerca de 111% da corrente nominal. Até essa verificação, a sinalização deve ser interpretada como desvio em relação ao padrão observado.

Para conferir o sensor de forma independente, a corrente em vazio também foi medida com um alicate amperímetro digital VC3266L+, que integra o kit de multímetro Exbom MD-180L, e o instrumento indicou 3,50 A (Figura 17). O valor fica muito próximo do limite inferior da faixa registrada pelo PZEM-004T e é coerente com a faixa de 3,5 a 4 A registrada em vazio.

Figura 17 – Medição da corrente em vazio com alicate amperímetro



Fonte: Autores (2026)

A comparação pontual com alicate amperímetro foi utilizada como verificação exploratória de ordem de grandeza e não como calibração metrológica do sensor. A determinação da exatidão das medições demanda ensaios em diferentes pontos de carga, instrumento de referência compatível com a forma de onda, identificação de sua especificação e análise dos desvios observados. O valor do alicate ficou 0,25 A (7,1%) abaixo da mediana de 3,75 A registrada pelo PZEM-004T em vazio e 0,03 A (0,9%) abaixo do limite inferior da faixa. O VC3266L+ é um instrumento de uso geral, sem indicação de medição true-RMS, o que limita a comparação em correntes com distorção, e a medição não foi repetida em outros estados de operação.

4.5.2 Desempenho do modelo

No conjunto de teste em blocos, com 304 leituras que a rede não viu durante o treino, o modelo acertou 99,7% das classificações. Esse número precisa ser lido

com cuidado por dois motivos. Primeiro, os rótulos de VAZIO e USINANDO foram definidos pela própria corrente, que também é entrada da rede; uma regra simples de “corrente acima de 4 A”, que reproduz o próprio critério de rotulagem, acerta 100% desse conjunto por construção, e o eventual ganho da rede está em estabilizar a classificação, ignorando picos isolados. Segundo, o teste tem 282 leituras de VAZIO e apenas 22 de USINANDO, de modo que classificar todas as leituras como VAZIO já daria 92,8% de acerto.

Os rótulos utilizados no treinamento foram definidos predominantemente a partir de limiares da corrente elétrica, variável também empregada como entrada do classificador. Consequentemente, a acurácia apresentada mede inicialmente a concordância do modelo com o procedimento de rotulagem e não comprova, por si só, a identificação independente do processo de corte. A validação do estado efetivo de usinagem demanda referência externa sincronizada, como observação operacional ou apontamentos de produção com resolução temporal suficiente.

Por isso, foi feito um teste mais exigente: a rede foi treinada com os dias 25 e 26 e testada nos dias 28 e 29, com 1.705 leituras. Nesse cenário, o acerto foi de 98,7%, contra 85,2% de quem sempre escolhesse a classe mais comum. O resultado indica que o modelo mantém a concordância com a regra de rotulagem em dias novos de operação, ainda que com acurácia ligeiramente inferior à do teste em blocos, o que não equivale a reconhecer de forma independente o processo de corte.

O desempenho também foi analisado por classe, com precisão, revocação, F1 macro e acurácia balanceada (Tabelas 14 e 15).

No teste em blocos, a MLP errou uma única leitura, de USINANDO classificada como VAZIO; e, como o conjunto não contém leituras de PARADA, o F1 macro, de 0,987, e a acurácia balanceada, de 0,977, foram calculados apenas sobre as classes presentes, VAZIO e USINANDO. No teste temporal, as métricas incluem também PARADA, com somente cinco exemplos: o F1 macro foi de 0,946 e a acurácia balanceada, de 0,919, e quatro das cinco leituras de PARADA foram reconhecidas. Restritos a VAZIO e USINANDO, esses valores seriam 0,974 e 0,979; por isso, a comparação direta entre os escores macro dos dois testes depende da composição de classes. Portanto, nos dois conjuntos, a rede não apresentou benefício incremental mensurável em relação à regra operacional simples. Com

outras cinco sementes de inicialização da rede (1 a 5), a acurácia variou de 99,0% a 99,7% no teste em blocos e de 98,3% a 99,2% no teste temporal, mas o F1 macro do teste temporal variou de 0,66 a 0,99, porque a classe PARADA, com poucas leituras, ora foi reconhecida, ora não.

Tabela 14 – Desempenho da MLP nos testes em blocos e temporal (execução final, semente 42)

Métrica	Teste em blocos	Teste temporal (28 e 29/09)
Leituras no teste (PARADA / VAZIO / USINANDO)	304 (0 / 282 / 22)	1.705 (5 / 1.453 / 247)
Acurácia da MLP	0,997	0,987
Classes no F1 macro e na acurácia balanceada	VAZIO e USINANDO	PARADA, VAZIO e USINANDO
F1 macro	0,987	0,946
Acurácia balanceada	0,977	0,919
F1 macro restrito a VAZIO e USINANDO	0,987	0,974
Precisão / revocação de PARADA	—	1,000 / 0,800
Precisão / revocação de VAZIO	0,996 / 1,000	0,994 / 0,990
Precisão / revocação de USINANDO	1,000 / 0,955	0,945 / 0,968
Classe majoritária (VAZIO)	0,928	0,852
Regra de limiar de 4 A	1,000	1,000
Modelo (semente; melhor época)	42; época 50	42; época 265

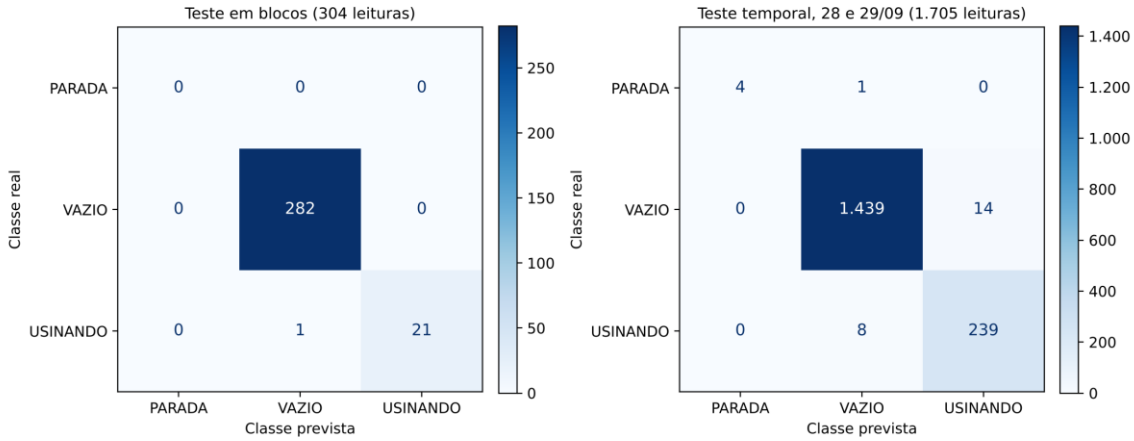
Fonte: Autores (2026)

Tabela 15 – Matrizes de confusão da MLP

Teste	Classe real	Prevista PARADA	Prevista VAZIO	Prevista USINANDO
Em blocos	VAZIO	0	282	0
Em blocos	USINANDO	0	1	21
Temporal	PARADA	4	1	0
Temporal	VAZIO	0	1.439	14
Temporal	USINANDO	0	8	239

Fonte: Autores (2026)

Figura 18 – Matrizes de confusão da MLP nos testes em blocos e temporal



Fonte: Autores (2026)

A Figura 18 apresenta as mesmas matrizes de confusão da Tabela 15 em forma de mapa de cores. As métricas por classe confirmam que, nessas condições, a MLP reproduz a regra de rotulagem com alta concordância, mas não a supera, e que a classe PARADA continua insuficientemente caracterizada para conclusões sobre o seu reconhecimento.

4.5.3 Avaliação com os usuários

A avaliação com os usuários foi planejada para os técnicos e operadores da AMJ que acompanham as fresadoras, com cinco a oito participantes. O protocolo previa que cada participante recebesse uma apresentação de cerca de dez minutos sobre o painel no Power BI e o indicador de LEDs, acompanhasse a máquina em operação usando o artefato e, em seguida, respondesse a um questionário anônimo no Google Forms. O texto de abertura do formulário informava que a participação era voluntária e anônima e que as respostas seriam usadas apenas de forma agregada. O questionário teve três partes: perfil do participante (função e tempo de experiência), as dez afirmações da SUS e as sete perguntas do GQM. O instrumento completo está no Apêndice A.

Na SUS, cada afirmação é respondida em uma escala de 1 (discordo totalmente) a 5 (concordo totalmente). Nas afirmações ímpares, que são positivas, subtrai-se 1 da resposta; nas pares, que são negativas, subtrai-se a resposta de 5. A soma dos dez valores é multiplicada por 2,5, o que gera uma pontuação de 0 a 100 por participante (BROOKE, 1996). Pontuações a partir de cerca de 70 correspondem

a uma usabilidade considerada boa na escala de adjetivos de Bangor, Kortum e Miller (2009), e esse valor foi adotado como critério de aceitação.

No GQM, o objetivo definido foi avaliar, do ponto de vista dos técnicos, se o artefato ajuda a acompanhar o funcionamento das fresadoras e a apoiar a manutenção. A Tabela 16 apresenta as perguntas derivadas desse objetivo e a métrica de cada uma. As perguntas fechadas usam a mesma escala de 1 a 5, e o critério de aceitação é média igual ou superior a 4 com pelo menos 70% de respostas 4 ou 5.

Tabela 16 – Perguntas e métricas do GQM

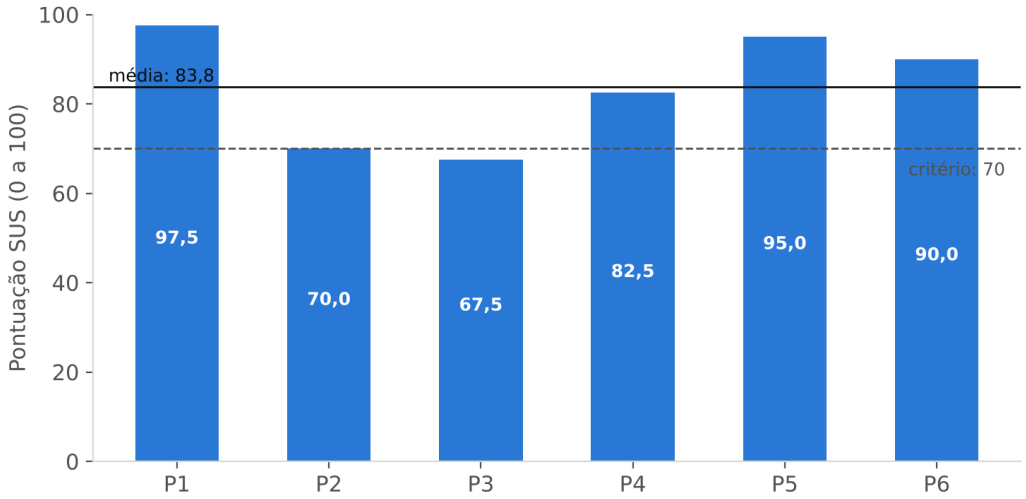
Pergunta	Tipo	Métrica
Q1. O painel permite saber se a máquina está parada, em vazio ou usinando?	Fechada	Média e % de respostas 4 ou 5
Q2. O indicador de LEDs é fácil de interpretar com o gabarito?	Fechada	Média e % de respostas 4 ou 5
Q3. Os dados de corrente ajudam a investigar falhas, como os desarmes do motor?	Fechada	Média e % de respostas 4 ou 5
Q4. A instalação do artefato não atrapalhou a operação da máquina?	Fechada	Média e % de respostas 4 ou 5
Q5. As informações ajudariam a calcular melhor o custo da hora-máquina?	Fechada	Média e % de respostas 4 ou 5
Q6. Que informação faltou no painel ou no indicador de LEDs?	Aberta	Temas mais citados
Q7. Que melhoria você sugere para usar o sistema no dia a dia?	Aberta	Temas mais citados

Fonte: Autores (2026), adaptado de Basili, Caldiera e Rombach (1994)

O questionário foi respondido por seis profissionais da AMJ: três operadores de máquina, um técnico de manutenção, um integrante da supervisão e um participante de outra função. Três deles trabalham com fresadoras há cinco anos ou mais, dois há um a três anos e um há menos de um ano.

A pontuação SUS média foi de 83,8, com desvio-padrão de 12,7 e valores entre 67,5 e 97,5 (Figura 19). A média supera o critério de 70 e corresponde a uma usabilidade boa na escala de Bangor, Kortum e Miller (2009). Cinco dos seis participantes ficaram acima de 70. A menor pontuação, 67,5, veio de um operador que concordou que o sistema é desnecessariamente complexo. Essa pontuação sinaliza um ponto de atenção relacionado à compreensão do sistema, mas, isoladamente, não identifica a causa da avaliação.

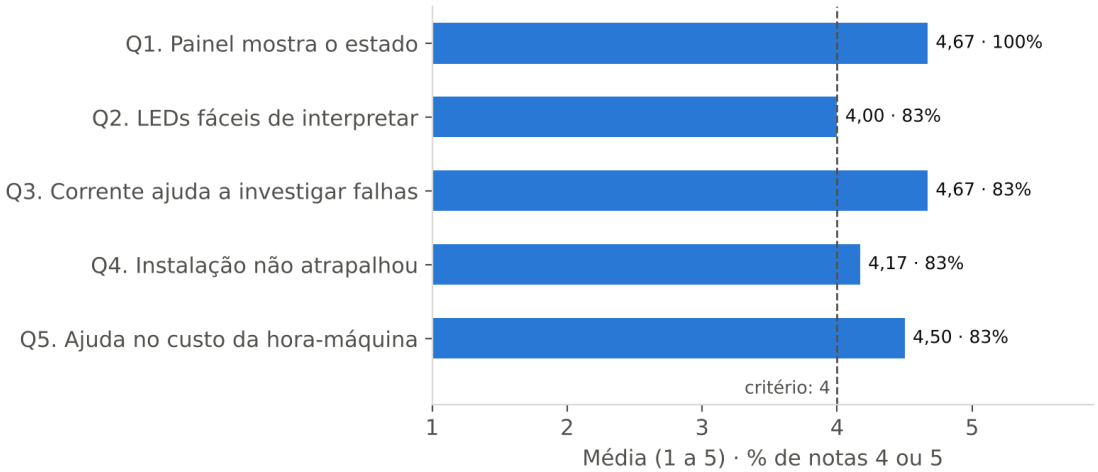
Figura 19 – Pontuação SUS por participante



Fonte: Autores (2026), com base nas respostas ao questionário

No GQM, as cinco perguntas fechadas atenderam ao critério de aceitação (Figura 20). As melhores avaliações foram para o painel, que permite saber o estado da máquina (média de 4,67 e 100% de notas 4 ou 5), e para o uso da corrente na investigação de falhas (4,67). A interpretação dos LEDs teve a menor média, exatamente 4,00. Um operador com mais de cinco anos de experiência deu nota 1 a essa pergunta e também à que trata da instalação não atrapalhar a operação. Essas respostas menos favoráveis sinalizam pontos de atenção relacionados à compreensão do indicador e à percepção da instalação; isoladamente, não identificam a causa das avaliações e recomendam verificação direta com os usuários.

Figura 20 – Média das perguntas fechadas do GQM



Fonte: Autores (2026), com base nas respostas ao questionário

Nas perguntas abertas, quatro dos seis participantes disseram que nada faltou no painel ou nos LEDs. As sugestões foram mostrar o valor da corrente no momento em que o LED indica uma condição, citada por dois participantes, acrescentar dados de vibração e temperatura, manter a máquina funcionando em quedas de energia e permitir comandos por voz. As duas primeiras reforçam os trabalhos futuros previstos; a queda de energia foge do escopo do artefato, que monitora a máquina, mas não a comanda.

Os resultados da SUS e do GQM indicam percepção favorável de usabilidade no contexto específico da empresa. Em razão do tamanho e da seleção da amostra, de conveniência, eles devem ser interpretados descritivamente, sem inferência de representatividade para outras organizações. De modo semelhante, as respostas GQM avaliam a utilidade percebida do painel e das sinalizações, mas não demonstram, isoladamente, redução de falhas, de tempo de manutenção ou de custo operacional.

4.6 Discussão

O protótipo realizou a aquisição periódica das grandezas elétricas da fresadora e a disponibilização de registros para acompanhamento em painel nas sessões analisadas, com custo direto de hardware estimado em cerca de R$ 300,00, e o firmware passou a incluir a classificação do estado da máquina no próprio dispositivo. A continuidade da operação e a atualização ponta a ponta não foram integralmente demonstradas, conforme as lacunas e interrupções descritas na Tabela 5. Esse resultado está alinhado ao que a literatura aponta sobre a IIoT como meio de dar visibilidade ao chão de fábrica (KHANG *et al.*, 2024) e sobre a viabilidade de executar modelos de aprendizado de máquina em hardware simples e barato (ABADADE *et al.*, 2023; OKANO *et al.*, 2025).

A Tabela 17 compara o artefato com soluções semelhantes, nos critérios que mais pesam para uma pequena empresa. As obras foram selecionadas entre as citadas na fundamentação teórica por tratarem do monitoramento de motores ou do consumo elétrico com dispositivos de baixo custo.

Tabela 17 – Comparação com soluções semelhantes

Critério	Este trabalho	De las Morenas, Moya-Fernández e López-Gómez (2023)	Santos *et al.* (2023)	Yasa *et al.* (2023)
Grandezas medidas	Corrente, tensão, potência, fator de potência e frequência	Corrente	Corrente e temperatura	Grandezas elétricas e energia (PZEM-004T)
Classificação no próprio dispositivo	Sim (MLP no ESP32)	Sim (Arduino)	Não (gêmeo digital por elementos finitos)	Não (só monitoramento)
Instalação sem alterar a máquina	Sim	Sim	Não informado	Sim
Custo	Baixo (≈ R$ 289,07 nos itens cotados, Tabela 4)	Baixo	Baixo na aquisição, mas exige simulação por elementos finitos	Baixo
Painel de acompanhamento	Sim (Power BI)	Não	Banco de dados	Sim (Firebase)
Testado em máquina em produção	Sim (fresadora da AMJ)	Não (máquinas de laboratório, sem carga)	Não informado	Não (protótipo)

Fonte: Autores (2026), com base nos trabalhos citados

A vantagem do artefato está na combinação dos critérios. No conjunto restrito de estudos selecionados para comparação, o artefato desenvolvido combina inferência embarcada, disponibilização de registros em painel e aplicação em fresadora industrial. Essa observação não estabelece ineditismo absoluto, uma vez que a comparação não decorre de revisão sistemática exaustiva e os estudos analisados apresentam diferenças nos sensores, no ambiente experimental e nas variáveis de desempenho. O trabalho mais próximo, de De las Morenas, Moya-Fernández e López-Gómez (2023), também executa aprendizado de máquina em uma placa de baixo custo a partir da corrente, mas foi avaliado em máquinas de laboratório e sem integração com um painel.

O achado mais relevante para a empresa, porém, veio do monitoramento em si e não do modelo. A frequência indicada de cerca de 70 Hz sugere que o motor pode estar trabalhando acima da rotação de projeto, hipótese que ajudaria a explicar os desarmes e o aquecimento relatados, mas que ainda precisa ser confirmada nos parâmetros e no histórico de falhas do inversor (item 4.1). Esse tipo de indício só foi possível porque passou a existir um registro periódico da máquina, que era justamente o problema identificado na primeira etapa do DSR.

Alguns limites também ficaram claros. O PZEM-004T foi projetado para redes senoidais de 45 a 65 Hz (PEACEFAIR, [20--]), e a saída de um inversor é modulada e de frequência variável; por isso, os valores de corrente e potência medidos entre o inversor e o motor devem ser vistos como indicativos. Pelo mesmo motivo, a comparação com a folha de dados, feita para alimentação senoidal a 60 Hz, deve ser vista como indicativa. Com o motor ligado em 380 V, a corrente em vazio registrada ficou cerca de 41% acima do valor de catálogo, e o limiar de 5,3 A corresponde a cerca de 111% da corrente nominal; esses resultados são compatíveis com a hipótese de operação fora das condições nominais, que ainda precisa ser confirmada nos parâmetros do inversor e com instrumento adequado. Para contornar parte dessas questões, a partir de 5 de outubro de 2026 a derivação de tensão do PZEM-004T foi transferida para o disjuntor geral da máquina, antes do inversor, onde a rede é senoidal e de 60 Hz, e o TC foi mantido na saída do inversor (Figura 8). Com isso, tensão e frequência passaram a refletir a rede, a máquina parada passou a ser registrada e uma nova versão do modelo, embarcada no firmware v25, foi treinada com esses dados (item 4.3.4); a potência e o fator de potência dessa configuração, porém, não representam o motor (item 4.3.1).

Por fim, a coleta cobriu poucos dias e uma única condição de velocidade do eixo, com poucas leituras de máquina parada e de corrente acima do padrão observado. Isso limita a generalização do modelo para outras rotações e outros tipos de peça, ponto que deve ser tratado com coletas mais longas e com rótulos independentes da corrente, como os apontamentos de produção da empresa.

5 CONCLUSÃO

Este trabalho teve como objetivo desenvolver e avaliar um artefato de IIoT de baixo custo para monitorar uma fresadora industrial e identificar o seu estado de operação com aprendizado de máquina embarcado. O estudo resultou em um protótipo IIoT funcional, com aquisição periódica de variáveis elétricas, publicação de registros por MQTT, disponibilização dos registros em painel e inferência embarcada por MLP de 107 parâmetros implementada no firmware. Os resultados de classificação reportados foram obtidos nas condições específicas da campanha e dependem dos critérios de rotulagem adotados. A avaliação com seis usuários indicou percepção favorável de usabilidade. As principais restrições envolvem a

compatibilidade metrológica do sensor na instalação inicial, o conjunto temporal limitado, a representação reduzida de alguns estados e a necessidade de rótulos independentes. Assim, os achados sustentam a viabilidade da arquitetura como protótipo de monitoramento, mas ainda não demonstram confiabilidade para diagnóstico causal de falhas ou manutenção preditiva. A continuidade requer novos ensaios no ponto de medição reposicionado, validação externa das classes e comparação com regras determinísticas.

O uso do DSR permitiu partir de um problema concreto da empresa, a falta de histórico e de medição de consumo das fresadoras, e chegar a uma solução testada no ambiente fabril. No caminho, o monitoramento indicou, de forma preliminar, frequência próxima de 70 Hz na saída do inversor, hipótese que a empresa pode verificar nos parâmetros e no histórico de falhas do inversor antes de qualquer ajuste.

Como limitações, destacam-se a medição feita na saída do inversor, fora da faixa especificada para o sensor, o período curto de coleta, a forte dependência dos rótulos em relação à corrente, a ausência de registro em campo das classes atribuídas pelo dispositivo e a diferença entre o modelo avaliado e o modelo embarcado no firmware. Como trabalhos futuros, sugere-se concluir a coleta na segunda montagem e validar nela o modelo embarcado e os limiares de decisão, usar os apontamentos de produção como rótulos independentes, calcular o consumo e o custo de energia por estado da máquina, recalibrar os limiares de sinalização para a ligação em 380 V com medições feitas por instrumento adequado e acrescentar sensores de vibração e temperatura para avançar rumo à manutenção preditiva.

REFERÊNCIAS

ABADADE, Y.; TEMOUDEN, A.; BAMOUMEN, H.; BENAMAR, N.; CHTOUKI, Y.; HAFID, A. S. A comprehensive survey on TinyML. **IEEE Access**, v. 11, 2023. DOI: https://doi.org/10.1109/ACCESS.2023.3294111.

BANGOR, A.; KORTUM, P.; MILLER, J. Determining what individual SUS scores mean: adding an adjective rating scale. **Journal of Usability Studies**, v. 4, n. 3, p. 114-123, 2009.

BASILI, V. R.; CALDIERA, G.; ROMBACH, H. D. The goal question metric approach. *In*: MARCINIAK, J. J. (ed.). **Encyclopedia of software engineering**. New York: Wiley, 1994. p. 528-532.

BROOKE, J. SUS: a “quick and dirty” usability scale. *In*: JORDAN, P. W. *et al*. (ed.). **Usability evaluation in industry**. London: Taylor & Francis, 1996. p. 189-194.

CHAUHAN, S.; SINGH, R.; GEHLOT, A.; AKRAM, S. V.; TWALA, B.; PRIYADARSHI, N. Digitalization of supply chain management with Industry 4.0 enabling technologies: a sustainable perspective. **Processes**, v. 11, n. 1, p. 96, 2023. DOI: https://doi.org/10.3390/pr11010096.

DAVID, R. *et al*. TensorFlow Lite Micro: embedded machine learning on TinyML systems. **arXiv**, 2021. DOI: https://doi.org/10.48550/arXiv.2010.08678.

DE LAS MORENAS, J.; MOYA-FERNÁNDEZ, F.; LÓPEZ-GÓMEZ, J. A. The edge application of machine learning techniques for fault diagnosis in electrical machines. **Sensors**, v. 23, n. 5, p. 2649, 2023. DOI: https://doi.org/10.3390/s23052649.

ELHANASHI, A. *et al*. Advancements in TinyML: applications, limitations, and impact on IoT devices. **Electronics**, v. 13, n. 17, p. 3562, 2024. DOI: https://doi.org/10.3390/electronics13173562.

HERCOG, D. *et al*. Design and implementation of ESP32-based IoT devices. **Sensors**, v. 23, n. 15, p. 6739, 2023. DOI: https://doi.org/10.3390/s23156739.

KHANG, A.; ABDULLAYEV, V.; HAHANOV, V.; SHAH, V. (ed.). **Advanced IoT technologies and applications in the Industry 4.0 digital economy**. Boca Raton: CRC Press, 2024. DOI: https://doi.org/10.1201/9781003434269.

LOPES, W. A. C. *et al.* Evaluating IoT hardware platforms through frugal innovation. **South American Development Society Journal**, v. 10, n. 29, p. 60-80, 2024. DOI: https://doi.org/10.24325/issn.2446-5763.v10i29p60-80.

LOPES, W. A. C.; MENDES, C. R.; MARIO, M. C. Sistema cyber-físico aplicado ao chão de fábrica com aquisição de dados para armazenamento em nuvem para aplicação na estrutura da indústria 4.0. **Anais do Encontro Nacional de Pós-Graduação**, v. 1, n. 1, p. 239-244, 2017.

LOPES, W. A. C.; RUGGERO, S. M.; OKANO, M. T. An assessment framework for IT/OT convergence maturity in industrial environments. *In*: IEEE ANNUAL COMPUTING AND COMMUNICATION WORKSHOP AND CONFERENCE (CCWC), 16., 2026, Las Vegas. **Proceedings** [...]. Las Vegas: IEEE, 2026. p. 1228-1233. DOI: https://doi.org/10.1109/CCWC67433.2026.11393794.

OKANO, M. T.; LOPES, W. A. C.; RUGGERO, S. M.; VENDRAMETTO, O.; FERNANDES, J. C. L. Edge AI for industrial visual inspection: YOLOv8-based visual conformity detection using Raspberry Pi. **Algorithms**, v. 18, n. 8, p. 510, 2025. DOI: https://doi.org/10.3390/a18080510.

OKANO, M. T.; LOPES, W. A. C.; FONG, C. K.; FERNANDES, J. C. L.; RUGGERO, S. M. Technological convergence of operational technology (OT) and information technology (IT) in the digital industry: conceptual analysis of OT, highlighting its convergences and differences with IT. *In*: MIZUYAMA, H. *et al*. (ed.). **Advances in production management systems**: cyber-physical-human production systems: human-AI collaboration and beyond. Cham: Springer Nature, 2026. p. 33-47. DOI: https://doi.org/10.1007/978-3-032-03538-7_3.

PEACEFAIR. **PZEM-004T V3.0**: user manual. [*S. l.*]: Peacefair, [20--].

PEFFERS, K.; TUUNANEN, T.; ROTHENBERGER, M. A.; CHATTERJEE, S. A design science research methodology for information systems research. **Journal of Management Information Systems**, v. 24, n. 3, p. 45-77, 2007. DOI: https://doi.org/10.2753/MIS0742-1222240302.

SANTOS, J. F. D.; TSHOOMBE, B. K.; SANTOS, L. H. B.; ARAÚJO, R. C. F.; MANITO, A. R. A.; FONSECA, W. S.; SILVA, M. O. Digital twin-based monitoring system of induction motors using IoT sensors and thermo-magnetic finite element analysis. **IEEE Access**, v. 11, p. 1682-1693, 2023. DOI: https://doi.org/10.1109/ACCESS.2022.3232063.

SCHMERSAL. **Inversor de frequência Praxi 20**: manual do usuário. [*S. l.*]: Schmersal, 2023.

SOUZA, F.; ROCHA, A. A.; SOUSA, M. O.; LOPES, W. A. C. Digital transformation in machinery maintenance in a loom construction company. **Revista e-TECH: Tecnologias para Competitividade Industrial**, v. 17, n. 1, 2024. DOI: https://doi.org/10.18624/etech.v17i1.1346.

WEG. **Folha de dados**: motor trifásico de indução W22 IR3 Premium, 3 cv, 4 polos, carcaça L90S/L, código 11397215. Jaraguá do Sul: WEG, 2026.

YASA, K. A.; PURBHAWA, I. M.; YASA, I. M. S.; TERESNA, I. W.; NUGROHO, A.; WINARDI, S. Prototype pemantauan konsumsi energi listrik pada Firebase menggunakan PZEM-004T. **Jurnal Eksplora Informatika**, v. 12, n. 2, p. 104-112, 2023.

APÊNDICE A – INSTRUMENTO DE AVALIAÇÃO COM OS USUÁRIOS

Questionário anônimo aplicado no Google Forms aos profissionais da AMJ após a apresentação do painel e do indicador de LEDs e o acompanhamento da máquina em operação.

Texto de abertura (convite e consentimento): “Este questionário faz parte do Trabalho de Graduação de alunos da Fatec São Bernardo do Campo sobre o sistema de monitoramento instalado na fresadora. A participação é voluntária e anônima e leva cerca de 5 minutos. As respostas serão usadas apenas de forma agregada no trabalho. Ao continuar, você concorda em participar.”

Seção 1 – Perfil: função e tempo de trabalho com fresadoras (múltipla escolha).

Seção 2 – Usabilidade (SUS). Instrução: “Pensando no painel do Power BI e no indicador de LEDs que você usou, marque o quanto concorda com cada afirmação.” Escala de 1 (discordo totalmente) a 5 (concordo totalmente).

SUS 1. Eu acho que gostaria de usar este sistema com frequência.

SUS 2. Eu acho o sistema desnecessariamente complexo.

SUS 3. Eu achei o sistema fácil de usar.

SUS 4. Eu acho que precisaria da ajuda de uma pessoa com conhecimentos técnicos para usar o sistema.

SUS 5. Eu acho que as várias funções do sistema estão bem integradas.

SUS 6. Eu acho que o sistema apresenta muita inconsistência.

SUS 7. Eu imagino que as pessoas aprenderão a usar este sistema rapidamente.

SUS 8. Eu achei o sistema confuso de usar.

SUS 9. Eu me senti confiante ao usar o sistema.

SUS 10. Eu precisei aprender várias coisas novas antes de conseguir usar o sistema.

Seção 3 – Objetivos do sistema (GQM). Q1 a Q5 na mesma escala de 1 a 5; Q6 e Q7 abertas e opcionais.

Q1. O painel permite saber se a máquina está parada, em vazio ou usinando?

Q2. O indicador de LEDs é fácil de interpretar com o gabarito?

Q3. Os dados de corrente ajudam a investigar falhas, como os desarmes do motor?

Q4. A instalação do artefato não atrapalhou a operação da máquina?

Q5. As informações ajudariam a calcular melhor o custo da hora-máquina?

Q6. Que informação faltou no painel ou no indicador de LEDs?

Q7. Que melhoria você sugere para usar o sistema no dia a dia?

Os resultados agregados estão na seção 4.5.3 (Figuras 19 e 20).